I2 · Restructurer des tableaux

~2.5 h

À la fin de cette séance vous saurez

- reconnaître les formats **large** et **long** et savoir lequel chaque tâche demande ;
- passer du large au long avec `pivot_longer()` et du long au large avec `pivot_wider()` ;
- séparer et réunir des colonnes avec `separate()` et `unite()` ;
- remplacer des codes d'erreur par `NA` et résumer plusieurs paramètres d'un coup.

Comment les données de qualité de l'eau ont été collectées

~ **Contexte simulé.** Pour comprendre les différences de croissance des algues, la coopérative et une ONG partenaire ont mesuré l'eau à **10 stations fixes** (`stations.csv` : position, zone, profondeur) **deux fois par mois pendant 3 ans** (2023–2025), avec une sonde multiparamètre descendue à mi-profondeur : **température** (°C), **salinité** (PSU), **pH**, **oxygène dissous** (mg/L) et **turbidité** (NTU). Quand le capteur de température tombait en panne, la sonde enregistrait le code d'erreur `-999` ; une électrode de pH défectueuse donnait parfois `0` . L'oxygène manque quand le capteur était en recalibrage.

L'ONG a aussi envoyé un fichier de synthèse préparé dans Excel, avec **une ligne par station et une colonne par mois** (température moyenne mensuelle).

Type de données : séries temporelles environnementales — mesures physico-chimiques répétées sur des sites fixes (quantitatives, continues).

Large ou long ?

La même information peut être rangée de deux façons :

- **Large** : une ligne par station, une colonne par mois (ou par paramètre). Facile à lire à l'œil, typique des rapports Excel.
- **Long** : une ligne par mesure, avec une colonne indiquant *ce qui* a été mesuré et une colonne pour la *valeur*. Nécessaire pour ggplot2 (couleur ou panneau par paramètre),

by Aroo Falinirina

pour `group_by() + summarise()`, et pour les tests statistiques.

Règle pratique : **stocker et analyser en format long, présenter en format large.**

```
library(dplyr); library(tidyr)
wide <- read.csv("data/water_quality_wide.csv", check.names = FALSE)   # keep "2023-01" as names
wide[1:3, 1:6]
```

```
#>   station 2023-01 2023-02 2023-03 2023-04 2023-05
#> 1    WQ01    28.2    29.0    28.4    27.5    25.3
#> 2    WQ02    29.0    28.7    28.7    27.5    25.7
#> 3    WQ03    29.0    28.6    28.1    27.3    25.3
```

```
dim(wide)
```

```
#> [1] 10 37
```

Du large au long : pivot_longer()

`pivot_longer()` prend les colonnes indiquées (`cols`), met leurs **noms** dans une nouvelle colonne (`names_to`) et leurs **valeurs** dans une autre (`values_to`).

```
long <- wide %>%
  pivot_longer(cols = -station,            # every column except station
               names_to = "month",
               values_to = "temp_mean")
head(long)
```

```
#> # A tibble: 6 × 3
#>   station month   temp_mean
#>   <chr>   <chr>       <dbl>
#> 1 WQ01    2023-01      28.2
#> 2 WQ01    2023-02      29
#> 3 WQ01    2023-03      28.4
#> 4 WQ01    2023-04      27.5
#> 5 WQ01    2023-05      25.3
#> 6 WQ01    2023-06      24.6
```

```
dim(long)                                # 10 stations x 36 months = 360 rows
```

```
#> [1] 360   3
```

Séparer une colonne : separate()

`"2023-01"` contient deux informations. `separate()` les sépare ; `convert = TRUE` transforme les morceaux en nombres. `unite()` fait l'inverse.

```
long <- long %>% separate(month, into = c("year", "month"), sep = "-", convert = T
RUE)
head(long, 3)
```

```
#> # A tibble: 3 × 4
#>   station  year month temp_mean
#>   <chr>   <int> <int>     <dbl>
#> 1 WQ01     2023     1      28.2
#> 2 WQ01     2023     2      29
#> 3 WQ01     2023     3      28.4
```

```
long %>% unite("period", year, month, sep = "/") %>% head(2)
```

```
#> # A tibble: 2 × 3
#>   station period temp_mean
#>   <chr>   <chr>      <dbl>
#> 1 WQ01    2023/1      28.2
#> 2 WQ01    2023/2      29
```

Plusieurs paramètres : nettoyer, puis pivoter

Le fichier des visites a une colonne par paramètre. Remplacez d'abord les codes d'erreur par `NA`, puis pivotez les cinq colonnes de paramètres. Une **plage** de colonnes `temp_C:turbidity_NTU` sélectionne toutes les colonnes entre les deux.

```
wq <- read.csv("data/water_quality_long.csv")
wq$date <- as.Date(wq$date, format = "%d/%m/%Y")
wq$temp_C[wq$temp_C == -999] <- NA          # error code of the temperature sensor
wq$pH[wq$pH == 0] <- NA                     # faulty pH electrode
wq_tidy <- wq %>%
  pivot_longer(temp_C:turbidity_NTU, names_to = "parameter", values_to = "value")
head(wq_tidy)
```

```
#> # A tibble: 6 × 4
#>   station date       parameter     value
#>   <chr>   <date>     <chr>         <dbl>
#> 1 WQ01    2023-01-05 temp_C        28.7
#> 2 WQ01    2023-01-05 salinity_psu  33.3
#> 3 WQ01    2023-01-05 pH             8.17
#> 4 WQ01    2023-01-05 DO_mgL         7.24
#> 5 WQ01    2023-01-05 turbidity_NTU  2.8
#> 6 WQ02    2023-01-05 temp_C        29
```

Maintenant un seul `group_by()` résume les cinq paramètres d'un coup :

```
wq_tidy %>%
  group_by(parameter) %>%
  summarise(n = sum(!is.na(value)), mean = mean(value, na.rm = TRUE),
            min = min(value, na.rm = TRUE), max = max(value, na.rm = TRUE))
```

```
#> # A tibble: 5 × 5
#>   parameter         n  mean   min   max
#>   <chr>         <int> <dbl> <dbl> <dbl>
#> 1 DO_mgL          712  7.18  6.06  8.7
#> 2 pH              714  8.15  7.99  8.31
#> 3 salinity_psu    720 34.4  31.6  36.5
#> 4 temp_C          708 26.1  21.8  30
#> 5 turbidity_NTU   720  4.39  0.8  33.1
```

Du long au large : pivot_wider()

Pour un tableau de rapport — une ligne par station, une colonne par paramètre — utilisez `pivot_wider()` : `names_from` donne les noms des nouvelles colonnes, `values_from` les valeurs.

```
station_table <- wq_tidy %>%
  group_by(station, parameter) %>%
  summarise(mean = round(mean(value, na.rm = TRUE), 2), .groups = "drop") %>%
  pivot_wider(names_from = parameter, values_from = mean)
station_table
```

```
#> # A tibble: 10 × 6
#>    station DO_mgL    pH salinity_psu temp_C turbidity_NTU
#>    <chr>    <dbl> <dbl>        <dbl>  <dbl>         <dbl>
#>  1 WQ01      7.13  8.15         34.7   26.2          3.22
#>  2 WQ02      7.12  8.15         34.7   26.2          3.45
#>  3 WQ03      7.21  8.15         34.6   26.1          3.08
#>  4 WQ04      7.17  8.16         34.7   26.1          3.48
#>  5 WQ05      7.19  8.16         34.6   26.3          3.75
#>  6 WQ06      7.15  8.16         34.7   26.2          3.66
#>  7 WQ07      7.23  8.15         34.6   26.1          3.45
#>  8 WQ08      7.16  8.15         34.0   26.2          7.06
#>  9 WQ09      7.2   8.15         33.9   26.1          6.97
#> 10 WQ10      7.25  8.15         33.9   26.0          5.78
```

R BASE

```
# the same table with tapply: one par
ameter at a time
round(tapply(wq$temp_C, wq$station, m
ean, na.rm = TRUE), 2)[1:4]
```

```
#>  WQ01  WQ02  WQ03  WQ04
#> 26.18 26.25 26.13 26.08
```

TIDYR + DPLYR

```
station_table %>% select(station, tem
p_C) %>% head(4)
```

```
#> # A tibble: 4 × 2
#>   station temp_C
#>   <chr>    <dbl>
#> 1 WQ01      26.2
#> 2 WQ02      26.2
#> 3 WQ03      26.1
#> 4 WQ04      26.1
```

› **À vous.** Construisez un tableau avec une ligne par **année** et une colonne par paramètre (valeurs moyennes). *Astuce : créez d'abord* `year` *avec* `format(date, "%Y")`.

⇩ checkpoint: I2_water_quality_clean.csv

⇩ checkpoint: I2_water_quality_monthly.csv

Travail d'application et quiz

Travail d'application I2

Script `scripts/i02_reshape.R`.

1. Pivotez `water_quality_wide.csv` en format long et séparez année et mois. Combien de lignes ?

by Aroo Falinirina

2. Température moyenne des 10 stations en **juillet 2024** (2 décimales) ?
3. Dans `water_quality_long.csv`, convertissez la date et remplacez les codes d'erreur (`-999`, pH `0`) par `NA`. Combien de températures manquent maintenant ?
4. Pivotez les cinq paramètres en format long. Combien de lignes ?
5. Oxygène dissous moyen de toutes les mesures (3 décimales) ?
6. Construisez le tableau par station (`pivot_wider`). Quelle station a la turbidité moyenne la plus élevée ? Combien de colonnes compte le tableau ?
7. Salinité moyenne en **2025** (3 décimales) ?

> Question 3 : comptez les `NA` **après** avoir remplacé `-999`. Question 6 : la colonne station compte comme une colonne.

Quiz : répondez en ligne sur le site du cours (votre score y est enregistré).