# I4 · Données d’enquête et texte

~3 h

### À la fin de cette séance vous saurez

- nettoyer des réponses texte avec **stringr** (espaces, casse, motifs) ;
- transformer les réponses en **facteurs**, y compris des échelles de Likert **ordonnées** ;
- séparer des réponses **à choix multiples** stockées dans une cellule et compter chaque option ;
- construire des variables de ménage à partir du tableau des membres (taille, nombre d’enfants) ;
- produire des tableaux croisés et des pourcentages prêts pour un rapport.

# Comment l’enquête a été menée

~ **Contexte simulé.** En juillet–août 2025, trois enquêteurs (Fara, Tojo, Mamy) ont interrogé **420 ménages** dans 6 villages de la coopérative, avec un questionnaire sur tablette (type KoboToolbox). Les ménages ont été tirés au sort dans la liste du village. Le chef de ménage répondait. L’export donne trois tableaux liés :

- `survey_households.csv` — une ligne par ménage : village, date d’entretien, enquêteur, caractéristiques du chef, revenu principal, **revenu mensuel** (Ariary), distance à la côte, **activités** (choix multiples, stockées sous la forme `fishing;seaweed`), avis « *L’AMP apporte des bénéfices à mon ménage* » sur une **échelle de Likert** à 5 niveaux, satisfaction de 1 à 5.
- `survey_members.csv` — une ligne par membre du ménage : lien avec le chef, sexe, âge, scolarisation, travail dans l’algoculture.
- `survey_assets.csv` — une ligne par bien possédé : pirogue, bateau, filets, téléphone…

Certains avis ont été saisis en minuscules ou avec des espaces en trop quand le clavier de la tablette a remplacé la liste de choix, et 5 ménages ont été synchronisés deux fois.

**Type de données :** enquête socio-économique — variables catégorielles (nominales et ordinales) et quantitatives, aux niveaux ménage et individu.

*by Aroo Falinirina*

```
hh <- read.csv("data/survey_households.csv", na.strings = "")
hh <- hh[!duplicated(hh), ]          # 5 households synchronised twice
dim(hh)
```

```
#> [1] 420  13
```

# Nettoyer du texte avec stringr

**stringr** rassemble des fonctions de texte aux noms cohérents, toutes commençant par `str_`. Leurs équivalents en R de base fonctionnent aussi :

| stringr | R de base | Ce qu'elle fait |
|---|---|---|
| `str_squish(x)` | `trimws(gsub("\\s+", " ", x))` | retire les espaces en trop (début, fin, doubles) |
| `str_to_lower()` / `str_to_upper()` / `str_to_sentence()` / `str_to_title()` | `tolower()` / `toupper()` | change la casse |
| `str_detect(x, "seaweed")` | `grepl("seaweed", x)` | TRUE si le motif est présent |
| `str_count(x, ";")` | — | compte un motif |
| `str_replace_all(x, "a", "b")` | `gsub("a", "b", x)` | remplace un motif |
| `str_split(x, ";")` | `strsplit(x, ";")` | découpe en morceaux |
| `str_sub(x, 1, 3)` | `substr(x, 1, 3)` | extrait des caractères |

```
library(stringr)
table(hh$mpa_benefits, useNA = "ifany")
```

```
#>
#>              Agree     Strongly agree  Strongly disagree              agree
#>                  5                  4                  1                  9
#>              Agree           Disagree            neutral            Neutral
#>                136                 46                  5                102
#>     strongly agree     Strongly agree  strongly disagree  Strongly disagree
#>                  4                 71                  1                 28
#>               <NA>
#>                  8
```

```
hh$mpa_benefits <- str_to_sentence(str_squish(hh$mpa_benefits))
table(hh$mpa_benefits, useNA = "ifany")
```

```
#>
#>             Agree          Disagree           Neutral    Strongly agree
#>               150                46               107                79
#> Strongly disagree              <NA>
#>                30                 8
```

# Facteurs ordonnés pour les échelles de Likert

Une réponse de Likert est **ordinale** : « Agree » est plus que « Neutral ». Sans niveaux, R trie les réponses par ordre alphabétique (« Agree », « Disagree », « Neutral »…), ce qui n'a pas de sens dans un tableau ou un graphique. Donnez les niveaux dans le bon ordre, et `ordered = TRUE` pour permettre les comparaisons.

```
lik <- c("Strongly disagree", "Disagree", "Neutral", "Agree", "Strongly agree")
hh$mpa_benefits <- factor(hh$mpa_benefits, levels = lik, ordered = TRUE)
table(hh$mpa_benefits)
```

```
#>
#> Strongly disagree          Disagree           Neutral             Agree
#>                30                46               107               150
#>    Strongly agree
#>                79
```

```
round(100 * prop.table(table(hh$mpa_benefits)), 1)    # percentages (NA excluded)
```

```
#>
#> Strongly disagree          Disagree           Neutral             Agree
#>               7.3              11.2              26.0              36.4
#>    Strongly agree
#>              19.2
```

```
sum(hh$mpa_benefits >= "Agree", na.rm = TRUE)          # "agree" or "strongly agre
e"
```

```
#> [1] 229
```

Regroupez des catégories quand une échelle est trop détaillée pour la taille de l'échantillon, en renommant les niveaux :

```
b3 <- hh$mpa_benefits
levels(b3) <- c("Disagree", "Disagree", "Neutral", "Agree", "Agree")   # same name
= merged
table(b3)
```

```
#> b3
#> Disagree  Neutral    Agree
#>       76      107      229
```

# Réponses à choix multiples

`activities` stocke plusieurs réponses dans une cellule : `"fishing;seaweed"` . Trois opérations utiles :

1. **compter** les réponses par ménage : `str_count(x, ";") + 1` ;
2. créer **une colonne TRUE/FALSE par option** : `str_detect(x, "seaweed")` ;
3. **découper** en une ligne par réponse pour compter chaque option (format long, séance I2).

```
library(tidyr); library(dplyr)
hh$n_activities <- str_count(hh$activities, ";") + 1
hh$does_seaweed <- str_detect(hh$activities, "seaweed")
table(hh$n_activities)
```

```
#>
#>   1   2   3
#> 132 145 143
```

```
acts <- hh %>% select(hh_id, village, activities) %>%
  separate_rows(activities, sep = ";")            # one row per activity
head(acts)
```

```
#> # A tibble: 6 × 3
#>   hh_id village    activities
#>   <chr> <chr>      <chr>
#> 1 HH001 Tsimanjaka trade
#> 2 HH001 Tsimanjaka gleaning
#> 3 HH001 Tsimanjaka agriculture
#> 4 HH002 Ankarabe   fishing
#> 5 HH002 Ankarabe   gleaning
#> 6 HH002 Ankarabe   trade
```

```
sort(table(acts$activities), decreasing = TRUE)
```

```
#>
#>     fishing     seaweed       trade    gleaning agriculture   livestock
#>         156         144         144         142         137         128
```

# Variables de ménage à partir des membres

Le tableau des membres a une ligne par personne. Compter les lignes par `hh_id` donne la taille du ménage ; compter avec une condition donne, par exemple, le nombre d'enfants scolarisés. Puis on joint au tableau des ménages (séance I3).

```
members <- read.csv("data/survey_members.csv", na.strings = "")
hh_vars <- members %>%
  group_by(hh_id) %>%
  summarise(hh_size = n(),
            n_children = sum(age < 18),
            n_seaweed_workers = sum(works_seaweed == "yes"))
hh <- left_join(hh, hh_vars, by = "hh_id")
summary(hh$hh_size)
```

```
#>    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
#>   2.000   3.000   6.000   5.581   8.000   9.000
```

# Tableaux croisés et pourcentages

`table()` croise deux variables ; `prop.table(t, margin = 1)` donne les pourcentages en ligne (chaque ligne fait 100 %). `addmargins()` ajoute les totaux.

```
t1 <- table(hh$village, b3)
addmargins(t1)
```

```
#>             b3
#>              Disagree Neutral Agree Sum
#>   Ambalakely        9      17    30  56
#>   Ankarabe          9      20    36  65
#>   Befasy           12      18    49  79
#>   Mahavelo         15      19    37  71
#>   Sarondrano       17      21    41  79
#>   Tsimanjaka       14      12    36  62
#>   Sum              76     107   229 412
```

```
round(100 * prop.table(t1, margin = 1), 1)      # % of each opinion within each vi
llage
```

```
#>             b3
#>              Disagree Neutral Agree
#>   Ambalakely     16.1    30.4  53.6
#>   Ankarabe       13.8    30.8  55.4
#>   Befasy         15.2    22.8  62.0
#>   Mahavelo       21.1    26.8  52.1
#>   Sarondrano     21.5    26.6  51.9
#>   Tsimanjaka     22.6    19.4  58.1
```

**R BASE**

```
round(100 * prop.table(table(hh$main_
income)), 1)
```

```
#>
#>     agriculture         fishing
salaried seaweed farming           tr
ade
#>             8.6            36.9
8.8            28.1            17.6
```

**DPLYR**

```
hh %>% count(main_income) %>%
  mutate(pct = round(100 * n / sum
(n), 1))
```

```
#>       main_income   n  pct
#> 1     agriculture  36  8.6
#> 2         fishing 155 36.9
#> 3        salaried  37  8.8
#> 4 seaweed farming 118 28.1
#> 5           trade  74 17.6
```

**⇩ checkpoint: I4_households_clean.csv**

# Travail d’application et quiz

## Travail d’application I4

Script `scripts/i04_survey.R` .

1. Retirez les ménages en double. Combien de ménages restent ?
2. Nettoyez `mpa_benefits` ( `str_squish` , `str_to_sentence` ) et transformez-le en facteur ordonné. Combien de ménages ont répondu exactement **« Agree »** ?
3. Pourcentage de ménages ayant répondu « Agree » **ou** « Strongly agree », parmi ceux qui ont répondu (1 décimale) ?
4. Nombre moyen d’activités par ménage (3 décimales) ?
5. Combien de ménages pratiquent l’**algoculture** ( `seaweed` dans `activities` ) ?
6. En découpant `activities` en une ligne par réponse : quelle est la **deuxième** activité la plus fréquente ?
7. Taille moyenne des ménages calculée à partir du tableau des membres (3 décimales ; jointure sur les ménages nettoyés) ?
8. Combien de membres sont scolarisés ( `in_school == "yes"` ) ?
9. Quel village a la plus forte **proportion** de ménages pratiquant l’algoculture ?

*by Aroo Falinirina*

10. Pourcentage de ménages dirigés par une femme (1 décimale) ?

> Question 3 : `mean(x >= "Agree", na.rm = TRUE)` ne fonctionne que sur un facteur **ordonné**.
> Question 9 : `prop.table(table(village, does_seaweed), margin = 1)` puis regardez la colonne `TRUE`.

**Quiz : répondez en ligne sur le site du cours (votre score y est enregistré).**

by Aroo Falinirina