I7 · Maîtriser ggplot2 (1) : échelles, couleurs, thèmes, panneaux

~3 h

À la fin de cette séance vous saurez

- distinguer **associer** (`aes()` , lié aux données) et **fixer** (une valeur constante) les couleurs, tailles et formes ;
- contrôler les **axes** : limites, graduations, étiquettes, échelles logarithmiques, zoom sans perdre de données ;
- choisir des **palettes de couleurs** claires, imprimables et lisibles par les daltoniens ;
- écrire des **étiquettes** complètes (titre, sous-titre, légende, unités) et ajuster le **thème** ;
- découper un graphique en **panneaux** avec `facet_wrap()` et `facet_grid()` .

⇩ checkpoint: I3_seaweed_analysis.csv **⇩ checkpoint: I2_water_quality_clean.csv**

> **i** Rappel de la grammaire (Débutant, séance 8) :
> `ggplot(données, aes(x, y, colour = ...)) + geom_*() + scale_*() + labs() + theme_*() + facet_*()` .
> Cette séance porte sur les quatre dernières couches : elles transforment un graphique correct en graphique **clair**.

Associer ou fixer ?

- **Dans `aes()`** : la couleur *dépend d'une colonne* → une légende est créée.
- **Hors de `aes()`** : la couleur est *la même pour tous les points* → pas de légende.

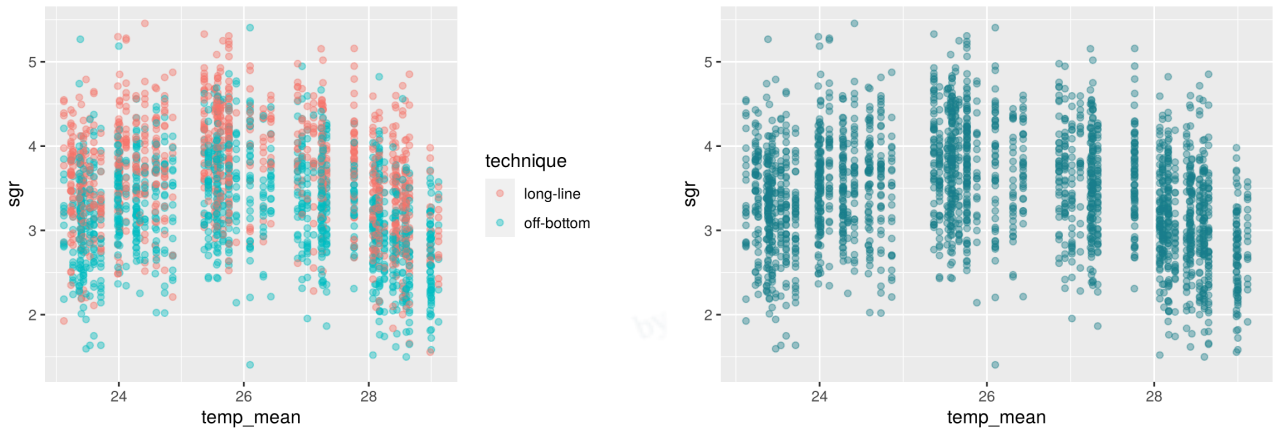
Erreur classique : `aes(colour = "blue")` : ggplot traite « blue » comme une catégorie appelée « blue » et la dessine en rouge avec une légende.

MAPPING

```
ggplot(seaweed, aes(temp_mean, sgr,
                    colour = technique)) +
  geom_point(alpha = 0.4, na.rm = TRUE)
```

SETTING

```
ggplot(seaweed, aes(temp_mean, sgr)) +
  geom_point(colour = "#1b7f8c",
             alpha = 0.4, na.rm = TRUE)
```

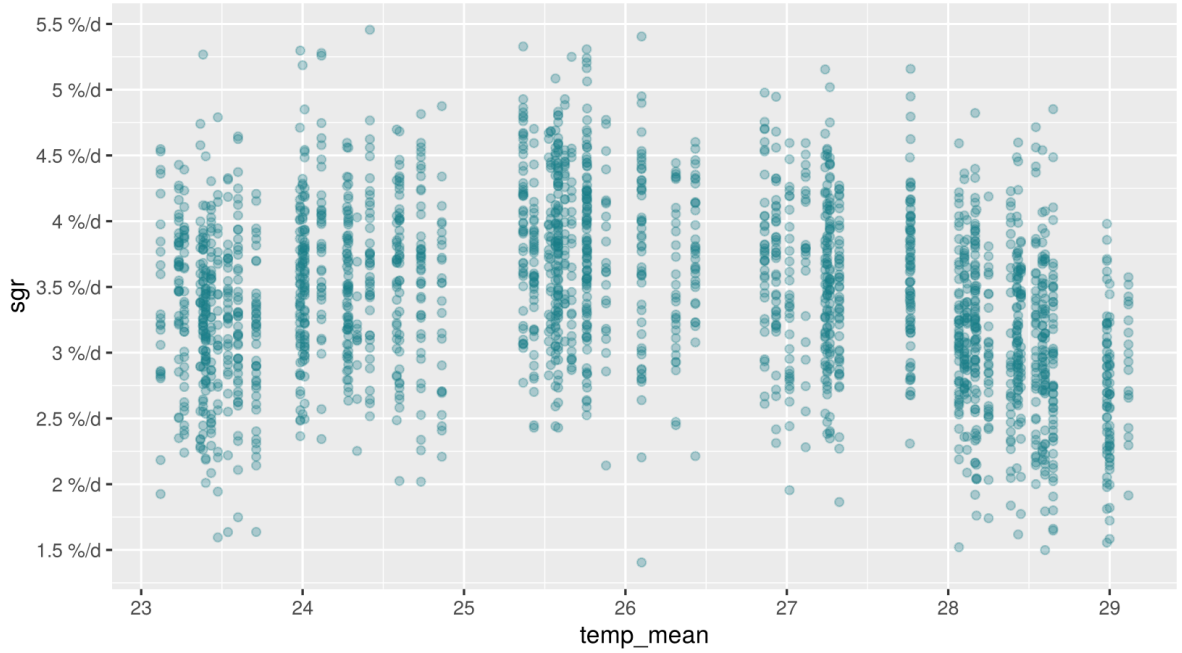


`alpha` (0 = transparent, 1 = opaque) révèle où les points se superposent : indispensable avec plus de 2 000 points.

Axes : limites, graduations, étiquettes

Chaque esthétique a une **échelle** : `scale_x_continuous()`, `scale_y_continuous()`, `scale_x_discrete()`, `scale_x_date()` … Leurs arguments principaux : `breaks` (position des graduations), `labels` (ce qu'elles affichent), `limits` (étendue), `expand` (espace autour des données).

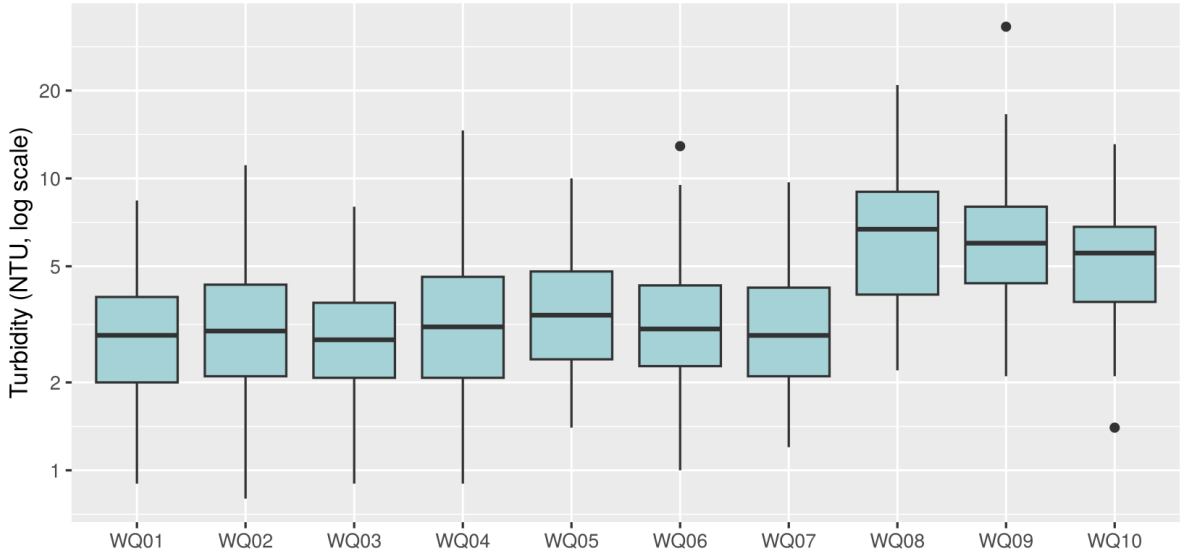
```
ggplot(seaweed, aes(temp_mean, sgr)) +
  geom_point(alpha = 0.3, colour = "#1b7f8c", na.rm = TRUE) +
  scale_x_continuous(breaks = seq(23, 30, by = 1)) +
  scale_y_continuous(breaks = seq(1, 6, by = 0.5),
                     labels = function(v) paste0(v, " %/d"))   # custom labels
```



! **Zoomer ou couper ?** `scale_y_continuous(limits = c(2, 5))` **supprime** les points hors de l'intervalle *avant* tout calcul (un boxplot ou une moyenne changerait !). `coord_cartesian(ylim = c(2, 5))` ne fait que **zoomer** : toutes les données sont gardées. Pour zoomer, utilisez `coord_cartesian()`.

Échelle logarithmique pour les variables asymétriques comme la turbidité ou le revenu : des distances égales représentent des *rapports* égaux.

```
turb <- subset(wq_tidy, parameter == "turbidity_NTU")
ggplot(turb, aes(station, value)) +
  geom_boxplot(fill = "#a8d5da") +
  scale_y_log10(breaks = c(1, 2, 5, 10, 20)) +
  labs(x = NULL, y = "Turbidity (NTU, log scale)")
```



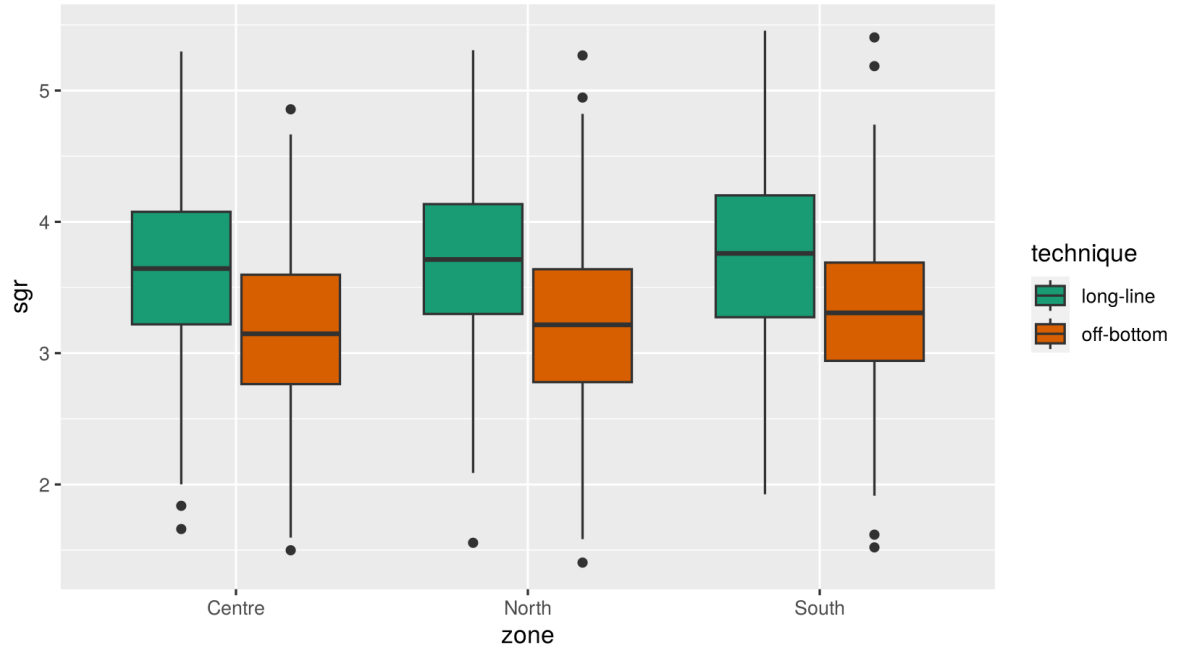
Des couleurs qui marchent pour tout le monde

Environ 1 homme sur 12 ne distingue pas le rouge du vert. Les rapports sont aussi souvent imprimés en gris. Trois bons choix :

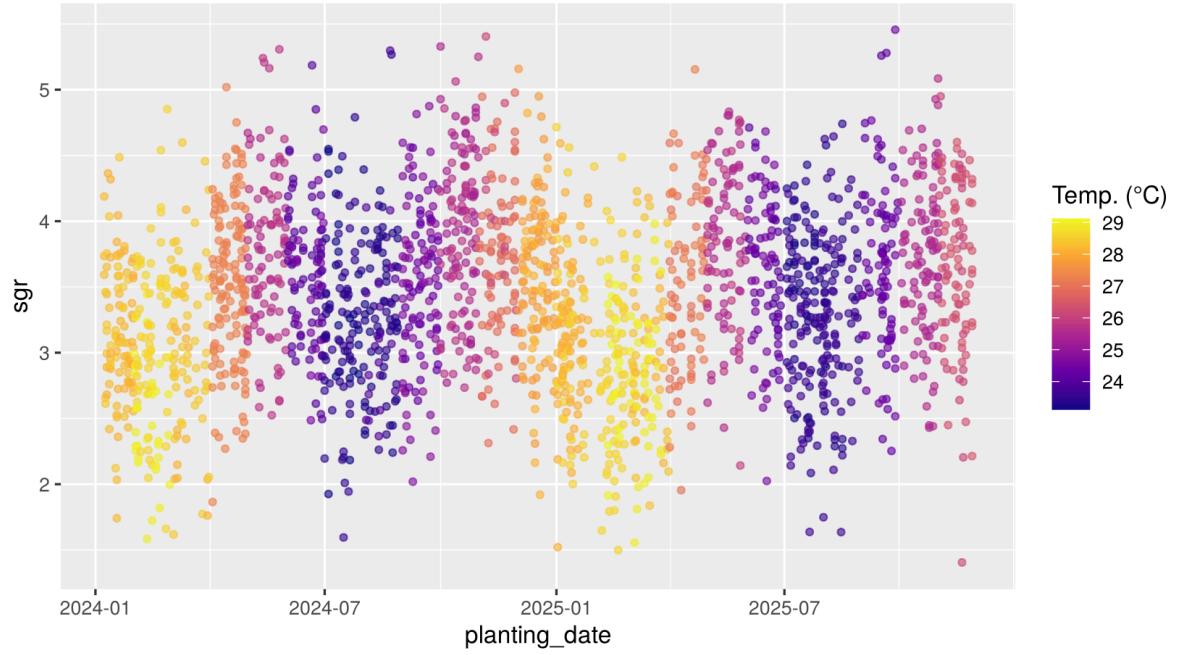
Données	Palette	Fonction
catégories (sites, techniques)	qualitative, peu de couleurs	`scale_colour_brewer(palette = "Dark2")` , `scale_fill_manual(values = c(...))`
une valeur continue (température, couverture)	séquentielle, adaptée aux daltoniens	`scale_colour_viridis_c()` , `scale_fill_viridis_c(option = "mako")`
une valeur autour d'un centre (anomalie, variation)	divergente	`scale_fill_distiller(palette = "RdBu")` , `scale_fill_gradient2()`

Utilisez `fill` pour les surfaces (barres, boîtes, polygones) et `colour` pour les points et les lignes.

```
ggplot(seaweed, aes(zone, sgr, fill = technique)) +
  geom_boxplot(na.rm = TRUE) +
  scale_fill_brewer(palette = "Dark2")
```




```r
ggplot(seaweed, aes(planting_date, sgr, colour = temp_mean)) +
  geom_point(alpha = 0.6, size = 1.2, na.rm = TRUE) +
  scale_colour_viridis_c(option = "plasma", name = "Temp. (°C)")
```

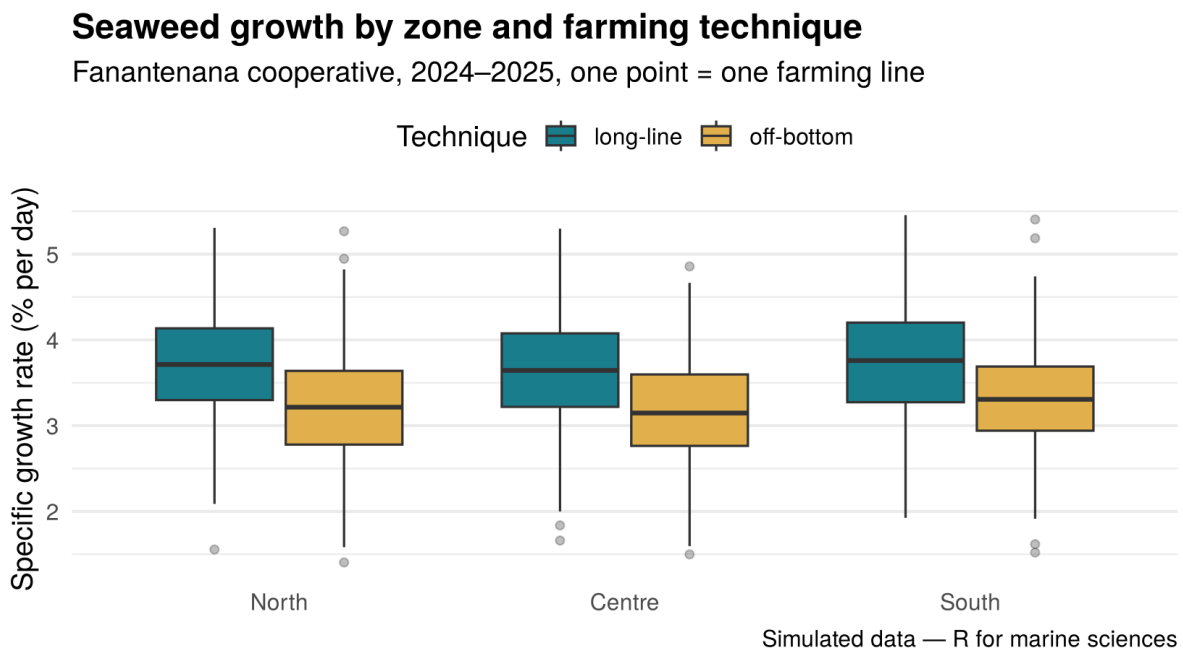


Pour imposer l'ordre des catégories (ex. Nord → Sud), fixez les niveaux du facteur avant de tracer : `seaweed$zone <- factor(seaweed$zone, levels = c("North", "Centre", "South"))` .

Étiquettes et thèmes

Une figure doit être compréhensible **seule** : dire *quoi*, *où*, *quand* et *dans quelle unité*. `labs()` fixe le titre, le sous-titre, la source, les titres d'axes et de légende. `theme_*()` change l'aspect général ; `theme()` ajuste n'importe quel détail.

```r
seaweed$zone <- factor(seaweed$zone, levels = c("North", "Centre", "South"))
ggplot(seaweed, aes(zone, sgr, fill = technique)) +
  geom_boxplot(na.rm = TRUE, outlier.alpha = 0.3) +
  scale_fill_manual(values = c("long-line" = "#1b7f8c", "off-bottom" = "#e3b04b")) +
  labs(title = "Seaweed growth by zone and farming technique",
       subtitle = "Fanantenana cooperative, 2024–2025, one point = one farming line",
       caption = "Simulated data — R for marine sciences",
       x = NULL, y = "Specific growth rate (% per day)", fill = "Technique") +
  theme_minimal(base_size = 13) +
  theme(legend.position = "top",
        plot.title = element_text(face = "bold"),
        panel.grid.major.x = element_blank())
```

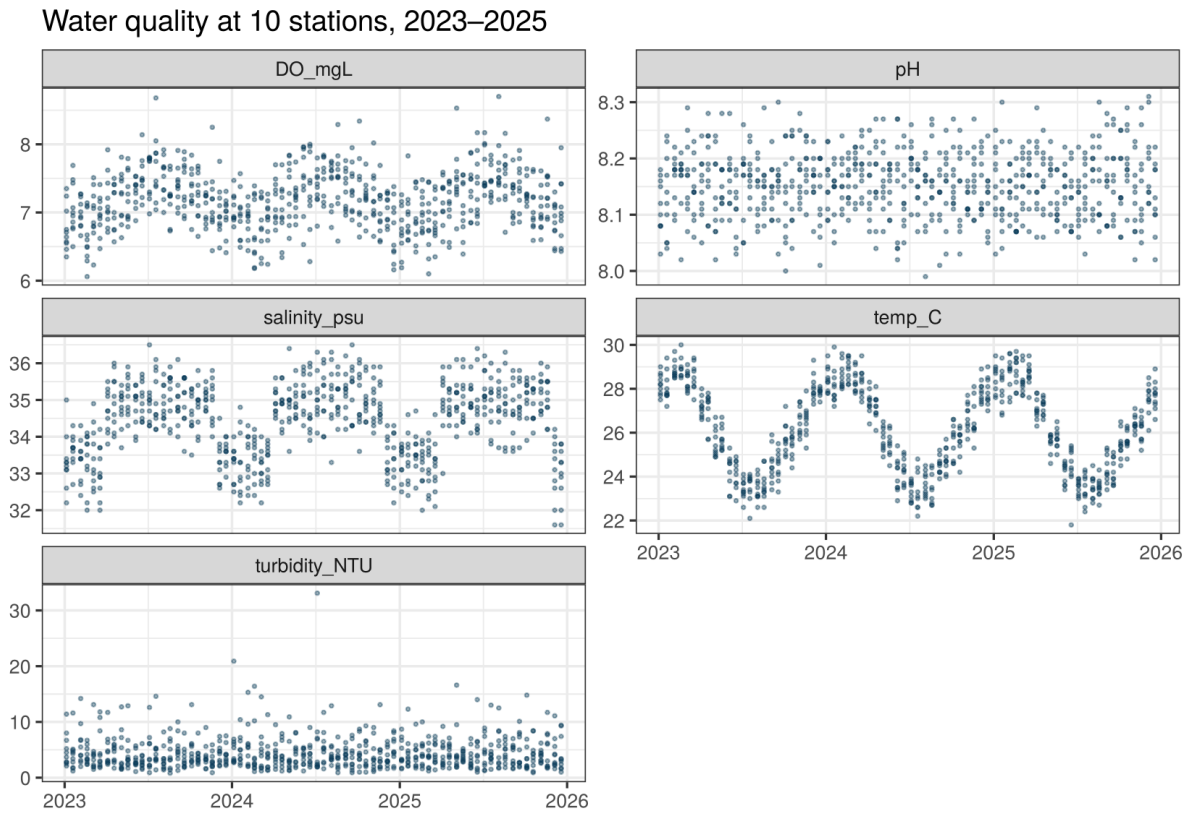


Élément de `theme()`	Contrôle	Exemple
`legend.position`	position de la légende	`"top"` , `"none"` , `c(0.9, 0.2)`
`axis.text.x`	texte des graduations x	`element_text(angle = 45, hjust = 1)`
`panel.grid.minor`	lignes de grille secondaires	`element_blank()` (supprimer)
`plot.title`	titre	`element_text(size = 16, face = "bold")`
`strip.text`	titres des panneaux	`element_text(face = "italic")`

Panneaux : facet_wrap() et facet_grid()

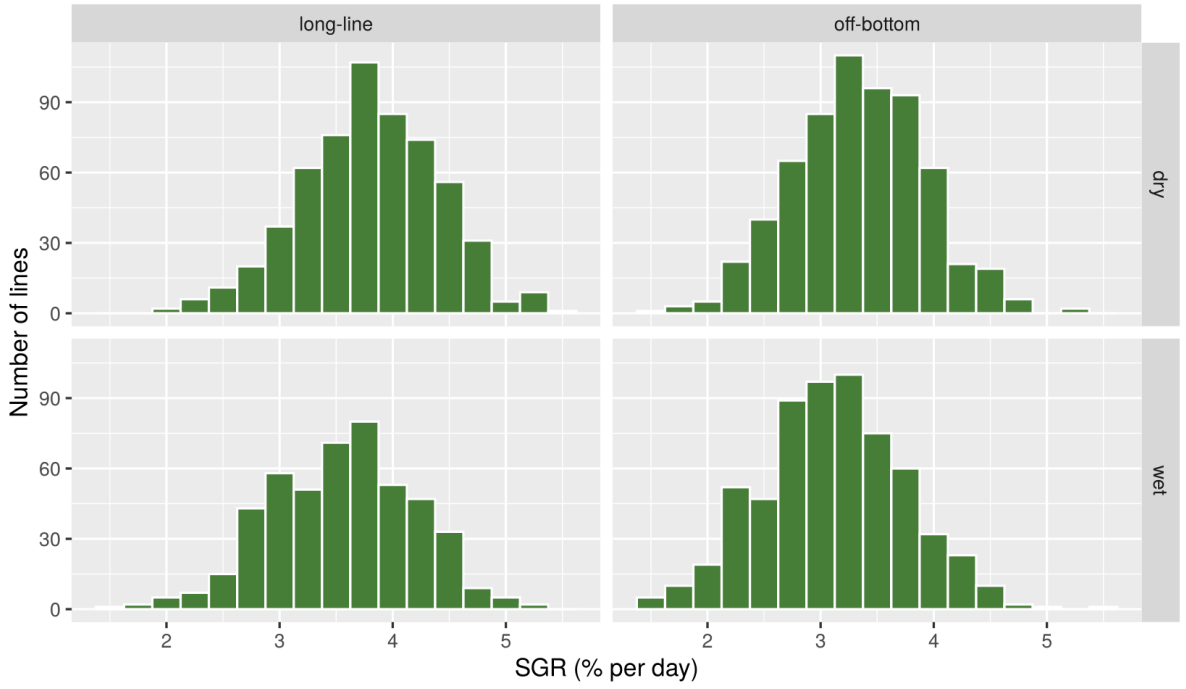
`facet_wrap(~ variable)` fait un panneau par catégorie. Avec le tableau **long** de qualité de l'eau (séance I2), une ligne de code trace les cinq paramètres — chacun avec son propre axe y grâce à `scales = "free_y"` .

```r
ggplot(wq_tidy, aes(date, value)) +
  geom_point(size = 0.5, alpha = 0.4, colour = "#0b3d5c", na.rm = TRUE) +
  facet_wrap(~ parameter, scales = "free_y", ncol = 2) +
  labs(x = NULL, y = NULL, title = "Water quality at 10 stations, 2023–2025") +
  theme_bw()
```



`facet_grid(lignes ~ colonnes)` croise deux variables :

```
ggplot(seaweed, aes(sgr)) +
  geom_histogram(binwidth = 0.25, fill = "#4a7d3a", colour = "white", na.rm = TRUE) +
  facet_grid(season ~ technique) +
  labs(x = "SGR (% per day)", y = "Number of lines")
```



by Aroo Falinirina

Travail d’application et quiz

Travail d’application I7

Script `scripts/i07_ggplot.R` . Enregistrez chaque figure avec `ggsave()` dans `outputs/` (16 × 10 cm, 300 dpi).

1. Nuage de points de `sgr` en fonction de `temp_mean` , coloré par `technique` (palette Dark2), avec `alpha = 0.4` , des étiquettes complètes et `theme_minimal()` . ggplot avertit que des lignes ont été retirées : combien de lignes n’ont pas de SGR ?
2. Boxplot de `sgr` par zone (North → Centre → South) et technique. Quelle est la **médiane** du SGR des lignes long-line en zone South (3 décimales, vérifiez avec `tapply(..., median, na.rm = TRUE)`) ?
3. Boxplot de la turbidité par station en échelle logarithmique. Quelle station a la turbidité médiane la plus élevée ?
4. Graphique en panneaux de tous les paramètres de qualité de l’eau avec des axes y libres. Combien de panneaux ?
5. Histogrammes du SGR avec `facet_grid(season ~ technique)` . Combien de lignes avec un SGR sont dans le panneau *wet × off-bottom* ?
6. Combien de lignes ont un SGR supérieur à 5 % par jour ?

> Question 2 : `tapply(seaweed$sgr, list(seaweed$zone, seaweed$technique), median, na.rm = TRUE)` donne un tableau zone × technique.

Quiz : répondez en ligne sur le site du cours (votre score y est enregistré).