I9 · Distributions, transformations et sens d’une p-value

~3 h

À la fin de cette séance vous saurez

- décrire la **forme** d’une distribution (symétrique, asymétrique, bimodale) et choisir entre **moyenne et médiane** ;
- reconnaître une **distribution normale** et la vérifier avec un histogramme et un **QQ-plot** (et connaître les limites du test de Shapiro–Wilk) ;
- **transformer** une variable asymétrique (log, racine carrée) et **re-transformer** le résultat (moyenne géométrique) ;
- expliquer simplement ce qu’est une **p-value** — et ce qu’elle n’est pas — à l’aide d’une **permutation** construite avec `sample()` et une boucle.

~ **Données de cette séance (simulées).** Pas de nouvelles données : nous réutilisons deux jeux que vous avez déjà nettoyés.

- **Lignes d’algues** (`I3_seaweed_analysis.csv`) : une ligne par corde de culture, issue des cahiers de la coopérative (dates de plantation et de récolte, poids frais pesés au peson). La variable étudiée est le **taux de croissance spécifique** (SGR, % par jour), une variable *continue*.
- **Enquête ménages** (`I4_households_clean.csv`) : 420 ménages interrogés en face à face par quatre enquêteurs en 2025. La variable étudiée est le **revenu mensuel** déclaré (ariary malgache, MGA) : continu, toujours positif et — comme la plupart des revenus — avec quelques valeurs très élevées.

Cette séance sert à **comprendre** avant de tester : les tests eux-mêmes viennent à la séance I10.

⇩ **checkpoint: I3_seaweed_analysis.csv** ⇩ **checkpoint: I4_households_clean.csv**

Échantillon et population

Les 420 ménages sont un **échantillon** ; ce que nous voulons connaître concerne la **population** (tous les ménages des 12 villages). Une statistique calculée sur l’échantillon (moyenne, proportion, corrélation) est une *estimation* : un autre échantillon donnerait une valeur un peu

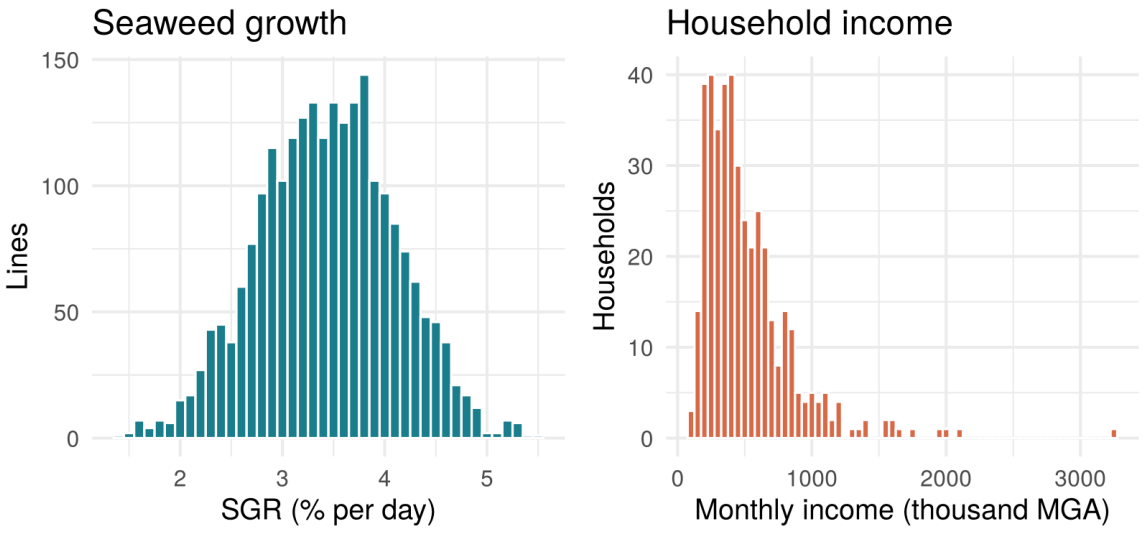
by Aroo Falinirina

différente. La statistique répond surtout à cette question : **le motif que je vois est-il plus grand que ce que le seul hasard de l'échantillonnage produirait ?** Gardez cette phrase en tête pendant toute la séance.

La forme d'une distribution

Une **distribution** décrit les valeurs que prend une variable et leur fréquence. **Tracez-la toujours d'abord** (débutant séance 8, intermédiaire séance I7) : un histogramme, ou une courbe de densité.

```
p_sgr <- ggplot(seaweed, aes(sgr)) +
  geom_histogram(binwidth = 0.1, fill = "#1b7f8c", colour = "white", na.rm = TRUE)
+
  labs(x = "SGR (% per day)", y = "Lines", title = "Seaweed growth") + theme_c()
p_inc <- ggplot(hh, aes(monthly_income_mga / 1000)) +
  geom_histogram(binwidth = 50, fill = "#d9694a", colour = "white") +
  labs(x = "Monthly income (thousand MGA)", y = "Households", title = "Household i
ncome") + theme_c()
p_sgr | p_inc
```



- Le **SGR** est à peu près **symétrique**, en cloche : la plupart des valeurs au centre, autant au-dessus qu'en dessous.
- Le **revenu** est **asymétrique à droite** (asymétrie positive) : beaucoup de revenus modestes et une longue queue de quelques revenus élevés. C'est typique des revenus, poids, abondances, concentrations : des valeurs qui ne peuvent pas être négatives et qui croissent de façon *multiplicative*.
- Une distribution à deux bosses est **bimodale** : cela signifie souvent que deux groupes sont mélangés (deux techniques, deux saisons…). Cherchez la variable de groupe !

Moyenne ou médiane ?

```
inc <- hh$monthly_income_mga
c(mean = mean(inc), median = median(inc))
```

```
#>   mean median
#> 516950 426000
```

```
sum(inc > 1e6)          # number of households above 1 million MGA
```

```
#> [1] 29
```

La moyenne est **tirée** par la longue queue : ici elle dépasse la médiane d'environ 90 000 MGA. Pour une variable asymétrique, la **médiane** (avec les quartiles) décrit mieux un ménage « typique » ; la moyenne reste utile pour des totaux (revenu total du village = moyenne × nombre de ménages). Pour une variable symétrique, moyenne et médiane sont proches et la moyenne (± ET) est le résumé habituel.

> › **À vous.** Calculez la moyenne et la médiane de `final_weight_kg` dans `seaweed`. Est-elle asymétrique ? Dans quel sens ? Tracez ensuite son histogramme pour vérifier.

La distribution normale

La distribution **normale** (gaussienne) est la courbe en cloche symétrique définie par deux nombres : sa moyenne (centre) et son écart-type (dispersion). Beaucoup de tests (tests « paramétriques », comme le test *t* et la corrélation de Pearson) supposent que les données — ou les erreurs du modèle — sont à peu près normales. Dans une distribution normale, environ **68 %** des valeurs sont dans moyenne ± 1 ET, **95 %** dans moyenne ± 2 ET (exactement 1,96) et **99,7 %** dans ± 3 ET.

R a quatre fonctions pour chaque distribution : `rnorm()` tire des valeurs au hasard, `dnorm()` donne la densité (hauteur de la courbe), `pnorm()` la probabilité en dessous d'une valeur, `qnorm()` la valeur sous laquelle se trouve une probabilité donnée.

```
pnorm(1.96) - pnorm(-1.96)   # ~0.95: area between -1.96 and +1.96 SD
```

```
#> [1] 0.9500042
```

by Aroo Falinirina

```r
qnorm(0.975)                  # 1.96: the value used for 95 % confidence intervals
(Session I8)
```

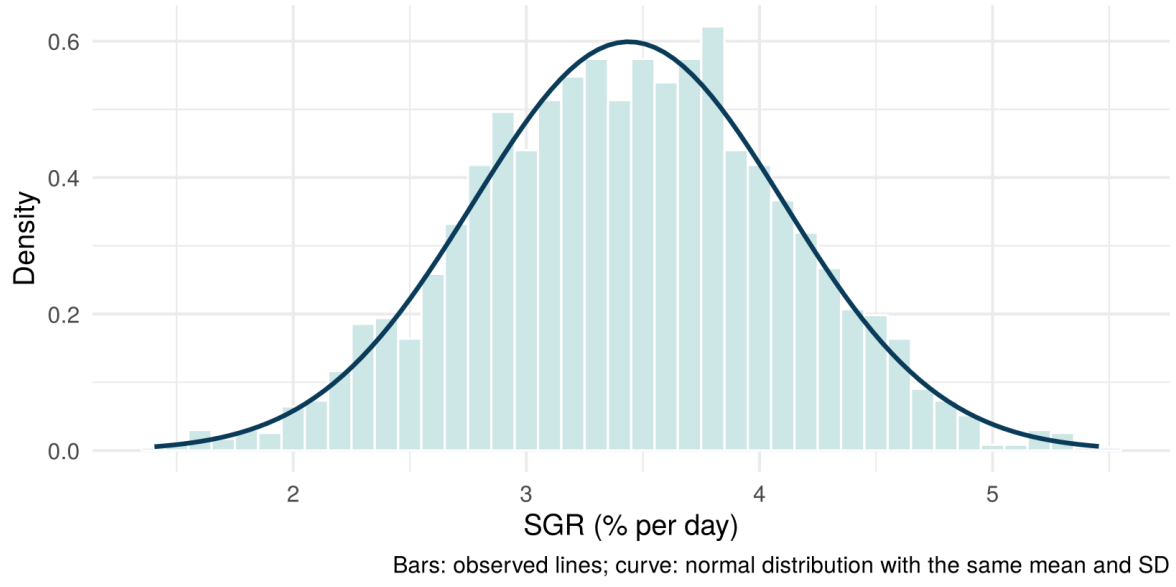
```
#> [1] 1.959964
```

```r
set.seed(1)                   # same random numbers for everybody (Beginner Session
6)
fake <- rnorm(1000, mean = 3.4, sd = 0.65)   # 1000 "ideal" SGR values
mean(abs(fake - mean(fake)) < 2 * sd(fake))  # proportion within mean ± 2 SD
```

```
#> [1] 0.949
```

Superposons la courbe théorique à l'histogramme réel du SGR. L'astuce : dessiner l'histogramme sur l'échelle de **densité** (`after_stat(density)`) pour que les barres et la courbe aient les mêmes unités.

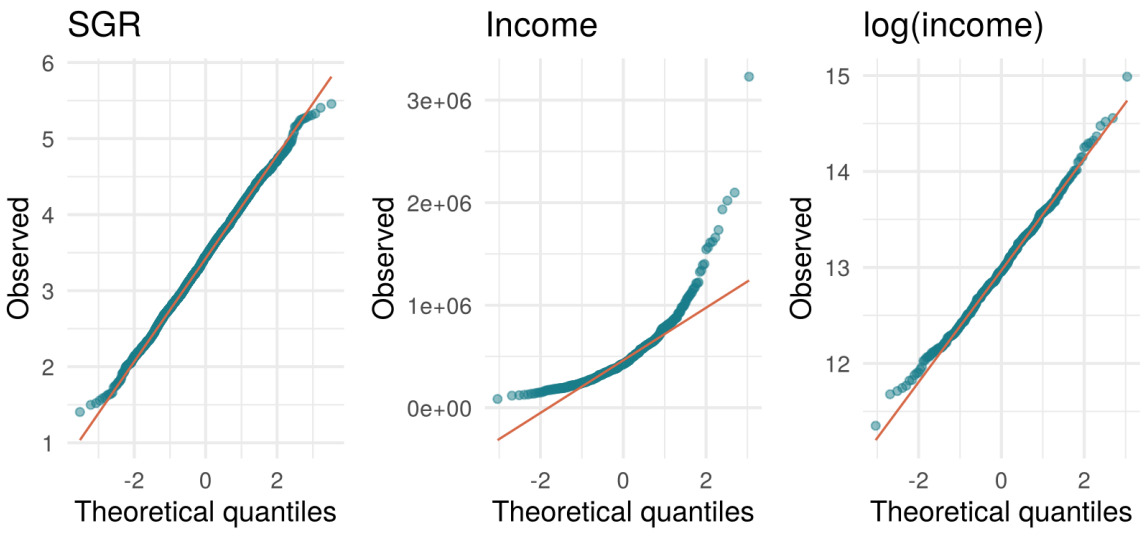
```r
m <- mean(seaweed$sgr, na.rm = TRUE); s <- sd(seaweed$sgr, na.rm = TRUE)
ggplot(seaweed, aes(sgr)) +
  geom_histogram(aes(y = after_stat(density)), binwidth = 0.1,
                 fill = "#cfe7ea", colour = "white", na.rm = TRUE) +
  stat_function(fun = dnorm, args = list(mean = m, sd = s),
                colour = "#0b3d5c", linewidth = 1) +            # normal curve wit
h the same mean and SD
  labs(x = "SGR (% per day)", y = "Density",
       caption = "Bars: observed lines; curve: normal distribution with the same m
ean and SD") + theme_c()
```



Vérifier la normalité

Le **QQ-plot** (quantile–quantile) est le meilleur contrôle visuel. Chaque point compare une valeur observée à la valeur attendue si les données étaient normales. **Des données normales tombent sur la droite** ; une courbe (forme de banane) indique une asymétrie ; des points qui ne quittent la droite qu'aux extrémités indiquent des queues épaisses ou des valeurs extrêmes.

```
qq <- function(x, title) {                    # small function (Session I6) to av
oid repeating code
  ggplot(data.frame(x = x), aes(sample = x)) +
    stat_qq(colour = "#1b7f8c", alpha = 0.5) + stat_qq_line(colour = "#d9694a") +
    labs(x = "Theoretical quantiles", y = "Observed", title = title) + theme_c()
}
qq(seaweed$sgr[!is.na(seaweed$sgr)], "SGR") | qq(inc, "Income") | qq(log(inc), "lo
g(income)")
```



BASE R

```
qqnorm(inc)
qqline(inc, col = "red")
```

GGPLOT2

```
ggplot(hh, aes(sample = monthly_incom
e_mga)) +
  stat_qq() + stat_qq_line()
```

Le test de Shapiro–Wilk, et pourquoi ne pas trop s'y fier

```
shapiro.test(inc)              # H0: the data come from a normal distribution
```

```
#>
#>  Shapiro-Wilk normality test
#>
#> data:  inc
#> W = 0.79851, p-value < 2.2e-16
```

```
shapiro.test(log(inc))
```

```
#>
#>  Shapiro-Wilk normality test
#>
#> data:  log(inc)
#> W = 0.99634, p-value = 0.4517
```

! `shapiro.test()` teste l'hypothèse nulle « les données sont normales ». Une petite p-value signifie « preuve claire de non-normalité ». Mais :

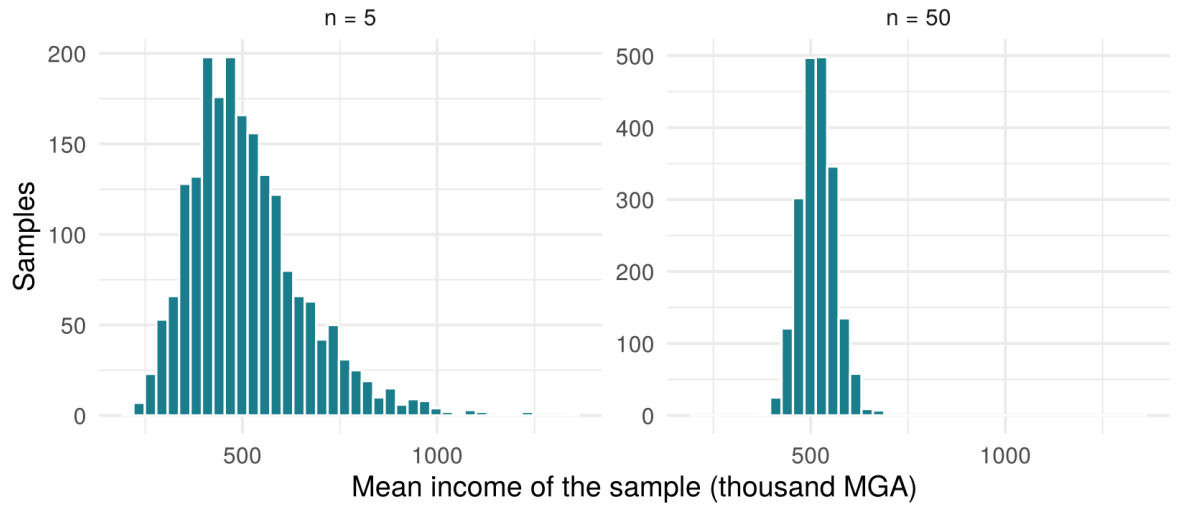
- avec **peu** de données (n < 20), il ne rejette presque jamais, même pour des données nettement asymétriques : il a peu de puissance ;
- avec **beaucoup** de données (n > 500), il rejette pour des écarts minimes et sans conséquence ;
- il n'accepte que 3 à 5000 valeurs.

Donc : **regardez d'abord l'histogramme et le QQ-plot**, et utilisez le test en complément. Ce qui compte, c'est de savoir si l'écart est assez grand pour fausser votre analyse — et avec de grands échantillons, les tests sur les **moyennes** sont assez robustes (voir la section suivante).

Pourquoi les moyennes se comportent bien : une simulation

Même quand les données sont asymétriques, la **moyenne d'un échantillon** devient à peu près normale quand l'échantillon est assez grand (le *théorème central limite*). Vérifions-le avec une boucle (séance I5) : nous tirons 2000 échantillons de 5 ou de 50 ménages et gardons leur revenu moyen.

```r
set.seed(2)
means5  <- replicate(2000, mean(sample(inc, 5)))    # replicate() = a short for-loop that collects results
means50 <- replicate(2000, mean(sample(inc, 50)))
sims <- data.frame(n = rep(c("n = 5", "n = 50"), each = 2000), mean = c(means5, means50) / 1000)
ggplot(sims, aes(mean)) + geom_histogram(bins = 40, fill = "#1b7f8c", colour = "white") +
  facet_wrap(~ n, scales = "free_y") +
  labs(x = "Mean income of the sample (thousand MGA)", y = "Samples") + theme_c()
```



Avec 5 ménages, les moyennes restent asymétriques ; avec 50, elles sont presque parfaitement en cloche, et beaucoup moins dispersées. C'est pourquoi un test *t* sur de grands groupes tolère des données non normales, alors qu'avec de petits groupes la normalité compte vraiment.

Transformations

Une **transformation** applique la même fonction à chaque valeur pour changer la forme de la distribution, en général pour la rendre plus symétrique (plus proche de la normale) et réduire le poids des valeurs extrêmes. L'ordre des valeurs ne change pas.

Situation	Transformation	R
Positif, asymétrique à droite (revenu, poids, concentration, biomasse)	logarithme	`log(x)`
Idem, mais avec des zéros	log de x + 1	`log1p(x)` (= `log(x + 1)`)
Comptages (individus par quadrat), asymétrie modérée	racine carrée	`sqrt(x)`
Proportions / pourcentages	pas de solution simple : analyser les effectifs (séance I10)	—

by Aroo Fallnirina

```r
hh$log_income <- log(hh$monthly_income_mga)    # natural log (base e); log10() also works
ggplot(hh, aes(log_income)) +
  geom_histogram(bins = 30, fill = "#d9694a", colour = "white") +
  labs(x = "log(monthly income)", y = "Households") + theme_c()
```



Après le log, le revenu est bien symétrique (et Shapiro–Wilk ne rejette plus la normalité plus haut). On peut alors calculer une moyenne **sur l'échelle log** — mais on la rapporte sur l'échelle d'origine en la **re-transformant** avec `exp()`. Le résultat, `exp(mean(log(x)))`, est la **moyenne géométrique** : une valeur « typique » non tirée par la queue, proche de la médiane.

```r
geo_mean <- function(x) exp(mean(log(x), na.rm = TRUE))   # a reusable function (Session I6)
c(arithmetic = mean(inc), geometric = geo_mean(inc), median = median(inc))
```

```
#> arithmetic  geometric     median
#>   516950.0   437185.9   426000.0
```

> **!** **Trois pièges.** (1) `log(0)` vaut `-Inf` et le `log` d'un nombre négatif vaut `NaN` : vérifiez d'abord `min(x)`, et utilisez `log1p()` s'il y a des zéros. (2) Une différence de moyennes sur l'échelle log est un **rapport** sur l'échelle d'origine : `exp(0.07)` ≈ 1,07, soit « 7 % plus élevé ». (3) Ne transformez pas « jusqu'à ce que le test soit significatif » : choisissez la transformation d'après la nature de la variable et les graphiques, **avant** de tester.

› **À vous.** `distance_coast_km` contient des zéros. Que renvoie `min(log(hh$distance_coast_km))` ? Comparez les QQ-plots de `distance_coast_km`, `sqrt(distance_coast_km)` et `log1p(distance_coast_km)`.

Ce que signifie vraiment une p-value

Question de la coopérative : les ménages qui cultivent les algues gagnent-ils plus ? Les moyennes géométriques diffèrent :

```
tapply(hh$monthly_income_mga, hh$does_seaweed, geo_mean)
```

```
#>    FALSE     TRUE
#> 426466.0 458491.4
```

```
obs <- mean(hh$log_income[hh$does_seaweed]) - mean(hh$log_income[!hh$does_seawee
d])
obs          # observed difference on the log scale
```

```
#> [1] 0.07240896
```

```
exp(obs)     # ratio: seaweed households earn ~7.5 % more (typical household)
```

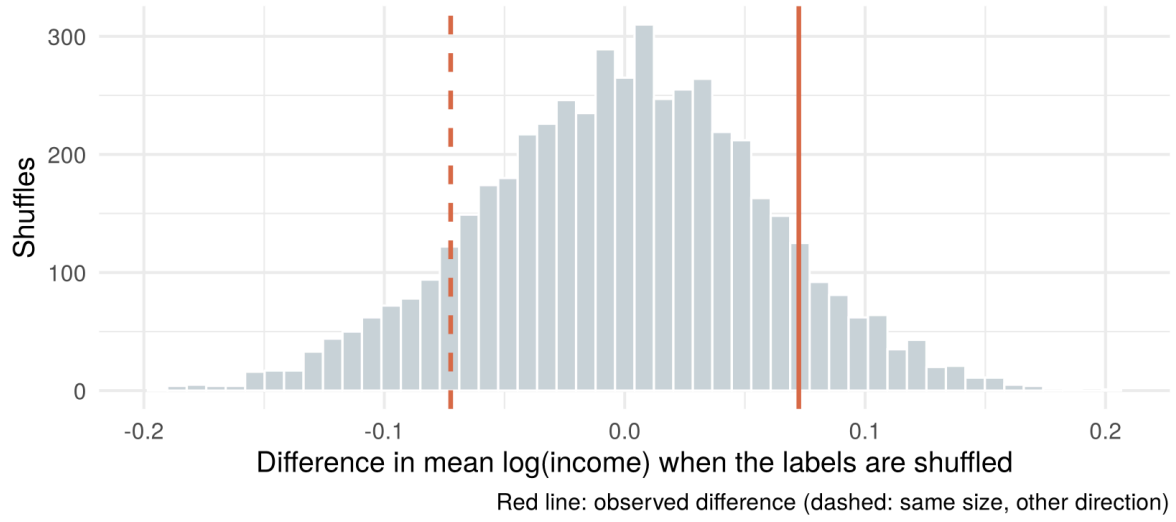
```
#> [1] 1.075095
```

Mais une différence de 7,5 % est-elle plus grande que ce que le **hasard** seul pourrait produire avec des groupes de 144 et 276 ménages ? Construisons la réponse nous-mêmes. Supposons que la culture d'algues n'ait **aucun** lien avec le revenu (c'est l'**hypothèse nulle**, H0). Alors les étiquettes « algues / pas d'algues » sont arbitraires : on peut les **mélanger** avec `sample()` et recalculer la différence, de nombreuses fois. On obtient la distribution des différences produites par le seul hasard — un **test de permutation**.

```r
set.seed(42)
n_perm <- 5000
perm <- numeric(n_perm)                        # empty vector to fill (Session I5)
for (i in 1:n_perm) {
  shuffled <- sample(hh$does_seaweed)          # same labels, random order
  perm[i] <- mean(hh$log_income[shuffled]) - mean(hh$log_income[!shuffled])
}
p_perm <- mean(abs(perm) >= abs(obs))          # share of shuffles at least as extre
me as what we observed
p_perm
```

```
#> [1] 0.2166
```

```r
ggplot(data.frame(d = perm), aes(d)) +
  geom_histogram(bins = 50, fill = "#c9d3d8", colour = "white") +
  geom_vline(xintercept = c(-obs, obs), colour = "#d9694a", linewidth = 1, linetyp
e = c(2, 1)) +
  labs(x = "Difference in mean log(income) when the labels are shuffled", y = "Shu
ffles",
       caption = "Red line: observed difference (dashed: same size, other directio
n)") + theme_c()
```



Environ **22 %** des mélanges aléatoires donnent une différence au moins aussi grande que celle observée. Cette proportion **est la p-value** :

> **p-value** = la probabilité d'observer une différence (ou une corrélation…) **au moins aussi extrême** que la nôtre **si l'hypothèse nulle était vraie**.

Ici, p ≈ 0.22 : une différence de cette taille est fréquente sous le seul effet du hasard ; les données n'apportent donc **pas de preuve convaincante** que les ménages cultivateurs gagnent plus. Un test *t* classique sur l'échelle log donne presque la même p-value — il utilise une formule mathématique au lieu des mélanges :

```
t.test(log_income ~ does_seaweed, data = hh)$p.value
```

```
#> [1] 0.2147531
```

! **Ce qu'une p-value N'EST PAS.**

- Ce n'est **pas** la probabilité que H0 soit vraie, ni la probabilité que le résultat soit « dû au hasard ».
- Un résultat **non significatif** (p > 0,05) ne **prouve pas** qu'il n'y a pas de différence : il dit que les données ne permettent pas de distinguer la différence du hasard (l'effet est peut-être faible, ou l'échantillon trop petit). Écrivez « pas de preuve d'une différence », pas « pas de différence ».
- Un résultat **significatif** ne dit pas que l'effet est **grand ou important** : avec des milliers de données, une différence minuscule devient significative. Rapportez toujours la **taille de l'effet** (différence, rapport, corrélation) avec son intervalle de confiance, à côté de la p-value.
- 0,05 est une **convention**, pas une loi de la nature : p = 0,049 et p = 0,051 racontent presque la même histoire.

› **À vous.** Relancez la permutation avec `set.seed(7)`. La p-value change-t-elle ? De combien ? Pourquoi n'est-elle jamais exactement égale à celle du test *t* ? (Indice : 5000 mélanges sont un échantillon de tous les mélanges possibles.)

Travail d'application et quiz

Travail d'application I9

Script `scripts/i09_distributions.R`. Partez des deux fichiers checkpoint ci-dessus.

1. Médiane et moyenne de `monthly_income_mga` (MGA).
2. D'après ces deux nombres, quelle est la forme de la distribution des revenus ?
3. Revenu moyen géométrique, arrondi à l'ariary près (écrivez une fonction `geo_mean()`).
4. p-value de `shapiro.test()` sur `log(monthly_income_mga)` (3 décimales).

by Aroo Falinirina

5. Pour `sgr` (sans NA), proportion des lignes comprises dans moyenne ± 2 ET (3 décimales). Est-ce proche de ce que prédit une distribution normale ?
6. Dans le village **Lovobe**, différence observée de SGR moyen : long-line − off-bottom (3 décimales). Faites ensuite un test de permutation (5000 mélanges de `technique`, dans Lovobe) et comparez votre p-value avec `t.test()`.
7. Tracez le QQ-plot de `final_weight_kg` et de son log. Lequel paraît le plus normal ?

Question 6 : d'abord `lv <- seaweed[seaweed$village == "Lovobe" & !is.na(seaweed$sgr), ]`, puis travaillez seulement avec `lv`. Dans la boucle, mélangez `lv$technique` avec `sample()`.

Quiz : répondez en ligne sur le site du cours (votre score y est enregistré).

by Aroo Falinirina