I10 · Comparer des moyennes et des proportions, corrélations : choisir le bon test

~3.5 h

À la fin de cette séance vous saurez

- choisir un test à partir de **la question** et du **type des variables**, et le justifier ;
- expliquer la différence entre tests **paramétriques** et **non paramétriques**, et quand préférer chacun ;
- comparer **deux moyennes** (groupes indépendants ou appariés) avec `t.test()` et `wilcox.test()` ;
- comparer des **pourcentages** avec `chisq.test()`, `prop.test()` et `fisher.test()` ;
- mesurer une **corrélation** avec Pearson ou Spearman, et reconnaître quand aucun coefficient de corrélation ne convient ;
- **rapporter** un résultat en une phrase claire (taille d'effet + test + p-value).

~ **Données de cette séance (simulées).** Quatre jeux que vous connaissez déjà, chacun répondant à une question de la coopérative ou du service de l'environnement :

- **Lignes d'algues** (`I3_seaweed_analysis.csv` , cahiers de la coopérative, 2024–2025) : la croissance (SGR) diffère-t-elle entre saison sèche et saison des pluies ? Suit-elle la température de l'eau ?
- **Enquête ménages** (`I4_households_clean.csv` , 420 entretiens en face à face, 2025) : les ménages dirigés par des femmes et par des hommes déclarent-ils des revenus différents ?
- **Registre des cultivateurs** (`I0_farmers.csv` , 96 membres de la coopérative) : femmes et hommes utilisent-ils les deux techniques dans les mêmes proportions ?
- **Qualité de l'eau** (`I2_water_quality_clean.csv`) : 10 stations fixes échantillonnées chaque mois avec une sonde multiparamètre, 2023–2025. 2025 a-t-elle été plus chaude que 2024 ? L'oxygène dissous est-il lié à la température ?

⇩ I3_seaweed_analysis.csv ⇩ I4_households_clean.csv ⇩ I0_farmers.csv

⇩ I2_water_quality_clean.csv

Choisir un test

Un test se choisit **avant** de regarder les p-values, à partir de trois questions : **(1)** quelle est ma question (différence de moyennes, de proportions, ou relation) ? **(2)** de quel type sont mes variables (numériques ou catégorielles) ? **(3)** les observations sont-elles indépendantes, ou les **mêmes unités sont-elles mesurées deux fois** (apparié) ? Ensuite, la forme des données (séance I9) indique si la version paramétrique est raisonnable.

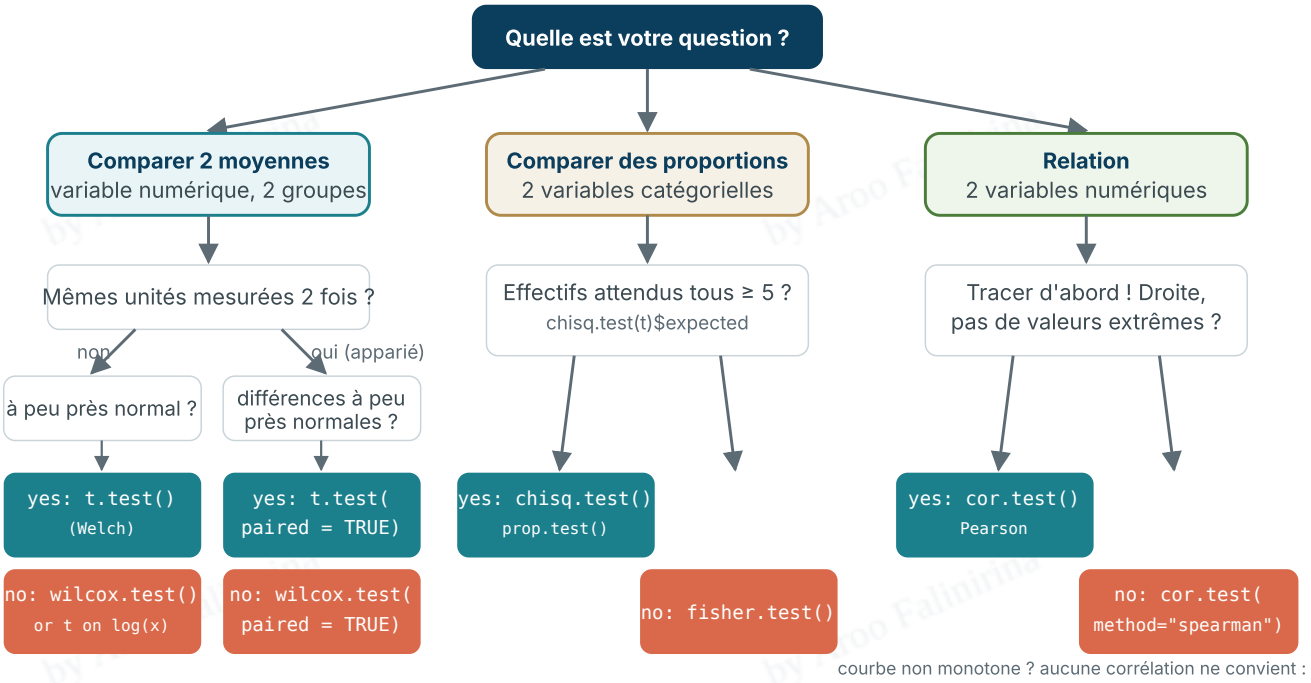


Schéma de décision pour les tests de cette séance. Bleu : test paramétrique ; orange : alternative non paramétrique ou exacte.

Paramétrique ou non paramétrique ?

	Paramétrique	Non paramétrique
Travaille sur	les valeurs elles-mêmes (moyennes, ET)	les **rangs** des valeurs (1er, 2e, 3e…)
Suppose	des données à peu près normales (ou de grands groupes, séance I9)	seulement que les distributions ont une forme semblable
Exemples	`t.test()`, `cor.test()` de Pearson	`wilcox.test()`, `cor.test(method = "spearman")` de Spearman
Atout	plus **puissant** quand les hypothèses sont vérifiées ; donne un effet dans les unités des données	**robuste** aux valeurs extrêmes et à l'asymétrie
Faiblesse	sensible aux valeurs extrêmes et à une forte asymétrie, surtout avec de petits échantillons	un peu moins puissant ; compare des « valeurs typiques » plutôt que des moyennes

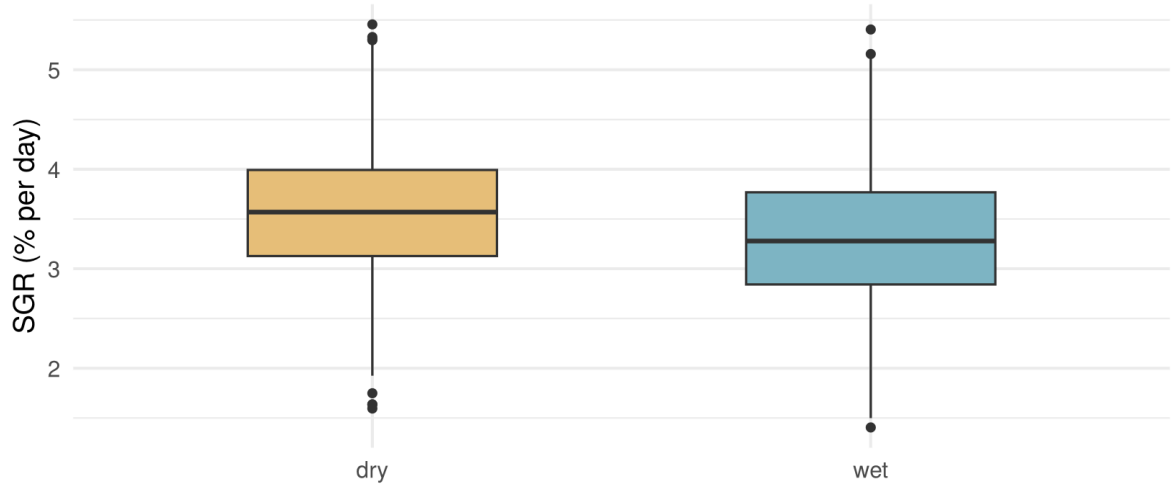
Règle pratique : à peu près normal (ou grands groupes sans valeurs extrêmes) → paramétrique. Petits groupes et nettement asymétrique, ou fortes valeurs extrêmes → soit **transformer** (log, séance I9) et utiliser le test paramétrique, soit utiliser le test non paramétrique. Choisissez une approche et justifiez-la — ne faites pas les deux pour garder celle qui « marche ».

Comparer deux moyennes : groupes indépendants

Croissance des algues en saison sèche et en saison des pluies

Le SGR est à peu près normal (séance I9) et les groupes sont grands : le **test t** est adapté. **Toujours tracer d'abord.**

```
ggplot(seaweed, aes(season, sgr, fill = season)) +
  geom_boxplot(width = 0.5, na.rm = TRUE, show.legend = FALSE) +
  scale_fill_manual(values = c(dry = "#e8c27a", wet = "#7fb8c4")) +
  labs(x = NULL, y = "SGR (% per day)") + theme_c()
```




```
tt <- t.test(sgr ~ season, data = seaweed)   # formula: numeric ~ group (2 levels)
tt
```

```
#>
#>  Welch Two Sample t-test
#>
#> data:  sgr by season
#> t = 9.5646, df = 2267.1, p-value < 2.2e-16
#> alternative hypothesis: true difference in means between group dry and group we
t is not equal to 0
#> 95 percent confidence interval:
#>  0.2071039 0.3139304
#> sample estimates:
#> mean in group dry mean in group wet
#>          3.562905          3.302388
```

Comment lire la sortie :

- `t = 9.56` : la différence de moyennes divisée par son erreur standard. Loin de 0 → la différence est grande par rapport au bruit d'échantillonnage.
- `df` : degrés de liberté. La valeur décimale montre que R a utilisé la version de **Welch** (par défaut), qui ne suppose pas des variances égales dans les deux groupes — gardez-la.
- `p-value < 2.2e-16` : le plus petit nombre que R affiche. Écrivez « p < 0,001 ».
- `95 percent confidence interval` : la différence sèche – pluies est comprise entre 0,21 et 0,31 % par jour. **C'est la taille d'effet à rapporter.**

```
tt$estimate                    # the two means
```

```
#> mean in group dry mean in group wet
#>          3.562905          3.302388
```

```r
diff(rev(tt$estimate))        # dry - wet
```

```
#> mean in group dry
#>         0.2605172
```

```r
tt$conf.int                   # 95 % CI of the difference
```

```
#> [1] 0.2071039 0.3139304
#> attr(,"conf.level")
#> [1] 0.95
```

```r
tt$p.value
```

```
#> [1] 2.821748e-21
```

> **i** **Rapportez-le ainsi.** « Les algues ont poussé plus vite en saison sèche (SGR moyen 3,56 contre 3,30 % j^{-1} ; différence 0,26, IC 95 % 0,21–0,31 ; test t de Welch, t = 9,56, ddl = 2267, p < 0,001). » Le lecteur apprend en une phrase le sens, la taille, la précision et le test.

Revenu des ménages dirigés par des femmes et par des hommes

Le revenu est fortement asymétrique à droite (séance I9). Deux options valides, **décidées avant de tester** :

OPTION A : NON PARAMÉTRIQUE (RANGS)

```r
wilcox.test(monthly_income_mga ~ head_sex,
            data = hh)
```

```
#>
#>  Wilcoxon rank sum test with continuity correction
#>
#> data:  monthly_income_mga by head_sex
#> W = 20948, p-value = 0.4251
#> alternative hypothesis: true location shift is not equal to 0
```

OPTION B : TEST T SUR LOG(REVENU)

```r
t.test(log(monthly_income_mga) ~ head_sex,
       data = hh)$p.value
```

```
#> [1] 0.6134224
```

by Aroo Falinirina

```
tapply(hh$monthly_income_mga, hh$head_sex, median)
```

```
#> Female   Male
#> 440000 421000
```

`wilcox.test()` (Wilcoxon de la somme des rangs, aussi appelé **Mann–Whitney**) classe tous les revenus ensemble et vérifie si un groupe a tendance à avoir des rangs plus élevés. Les deux options concordent : **pas de preuve d'une différence** (p = 0,43 et 0,61). L'option B a un avantage : `exp()` de la différence des moyennes de log est un **rapport** de moyennes géométriques (« x % plus élevé »), facile à interpréter. Le message « with continuity correction » : avec de grands échantillons R utilise une approximation — c'est normal.

Données appariées : les mêmes unités mesurées deux fois

L'eau était-elle plus chaude en 2025 qu'en 2024 ? Les **mêmes 10 stations** ont été mesurées les deux années : une station chaude l'est les deux années. Traiter les deux années comme des groupes indépendants mélangerait les grandes différences **entre stations** et le petit changement **entre années**. Un test **apparié** travaille sur les 10 différences (2025 − 2024), une par station.

```
wq$year <- as.integer(format(wq$date, "%Y"))
station_year <- wq %>%
  filter(year %in% c(2024, 2025)) %>%
  group_by(station, year) %>%
  summarise(temp = mean(temp_C, na.rm = TRUE), .groups = "drop") %>%
  pivot_wider(names_from = year, values_from = temp, names_prefix = "y")   # Sessi
on I2: one row per station
station_year
```

```
#> # A tibble: 10 × 3
#>    station y2024 y2025
#>    <chr>   <dbl> <dbl>
#>  1 WQ01     26.3  26.1
#>  2 WQ02     26.2  26.2
#>  3 WQ03     26.3  26.1
#>  4 WQ04     26.0  26.0
#>  5 WQ05     26.5  26.3
#>  6 WQ06     26.4  26.0
#>  7 WQ07     26.1  26.1
#>  8 WQ08     26.2  26.2
#>  9 WQ09     26.0  26.0
#> 10 WQ10     26    26.0
```

```r
t.test(station_year$y2025, station_year$y2024, paired = TRUE)
```

```
#>
#>  Paired t-test
#>
#> data:  station_year$y2025 and station_year$y2024
#> t = -2.7964, df = 9, p-value = 0.02084
#> alternative hypothesis: true mean difference is not equal to 0
#> 95 percent confidence interval:
#>  -0.18050330 -0.01906192
#> sample estimates:
#> mean difference
#>     -0.09978261
```

Les lignes doivent être **dans le même ordre** pour les deux vecteurs (ici garanti par le tableau large : une ligne = une station). Avec seulement 10 différences, vérifiez leur forme (`hist(station_year$y2025 - station_year$y2024)`) ; en cas de doute, utilisez `wilcox.test(..., paired = TRUE)` .

Regardez la taille d'effet ! La différence vaut −0,10 °C (IC 95 % −0,18 à −0,02) : statistiquement significative (p = 0,02), mais un dixième de degré est bien plus petit que la variation saisonnière (plusieurs °C). **Significatif ne veut pas dire important.** Savoir si 0,1 °C compte est une question écologique, pas statistique.

Comparer des pourcentages

Femmes et hommes utilisent-ils les deux techniques dans les mêmes proportions ? Les deux variables sont **catégorielles** : on compare des **effectifs** dans un tableau de contingence, jamais directement les pourcentages (ils cachent la taille de l'échantillon).

```r
tab <- table(farmers$sex, farmers$technique)
tab
```

```
#>
#>     long-line off-bottom
#>   F        29         26
#>   M        14         27
```

```r
round(prop.table(tab, margin = 1) * 100, 1)   # % per row: within each sex
```

```
#>
#>     long-line off-bottom
#>   F      52.7       47.3
#>   M      34.1       65.9
```

ina

53 % des femmes utilisent les cordes flottantes contre 34 % des hommes. Une différence de 19 points de pourcentage est-elle convaincante avec 96 cultivateurs ? Le **test du khi-deux** compare les effectifs observés aux effectifs **attendus** si la technique ne dépendait pas du sexe. Son approximation n'est fiable que si **tous les effectifs attendus sont ≥ 5** — vérifiez-le.

```
chi <- chisq.test(tab)
chi$expected          # all > 5: the chi-square is OK
```

```
#>
#>     long-line off-bottom
#>   F  24.63542   30.36458
#>   M  18.36458   22.63542
```

```
chi
```

```
#>
#>  Pearson's Chi-squared test with Yates' continuity correction
#>
#> data:  tab
#> X-squared = 2.5712, df = 1, p-value = 0.1088
```

```
fisher.test(tab)      # exact test: use it when an expected count is < 5
```

```
#>
#>  Fisher's Exact Test for Count Data
#>
#> data:  tab
#> p-value = 0.09696
#> alternative hypothesis: true odds ratio is not equal to 1
#> 95 percent confidence interval:
#>  0.8652186 5.4223588
#> sample estimates:
#> odds ratio
#>   2.133751
```

```
prop.test(tab)        # same test, presented as two proportions with a CI of the d
ifference
```

```
#>
#>  2-sample test for equality of proportions with continuity correction
#>
#> data:  tab
#> X-squared = 2.5712, df = 1, p-value = 0.1088
#> alternative hypothesis: two.sided
#> 95 percent confidence interval:
#>  -0.03163446  0.40325309
#> sample estimates:
#>    prop 1    prop 2
#> 0.5272727 0.3414634
```

Les trois concordent (p ≈ 0,10–0,11) : **pas de preuve convaincante** que la technique dépende du sexe. Mais regardez l'intervalle de confiance de `prop.test()` : la différence pourrait aller d'environ −3 à +40 points de pourcentage. Avec seulement 96 cultivateurs, nous **ne pouvons simplement pas trancher** — ce n'est pas une preuve que femmes et hommes cultivent de la même façon. Rapportez : « 53 % des femmes et 34 % des hommes utilisaient les cordes flottantes (χ^2 = 2,57, ddl = 1, p = 0,11 ; n = 96) ».

Pour un tableau 2 × 2, R applique par défaut la **correction de continuité de Yates** (un petit ajustement prudent). `fisher.test()` donne aussi un **odds ratio** (rapport des cotes), une taille d'effet courante pour les tableaux 2 × 2.

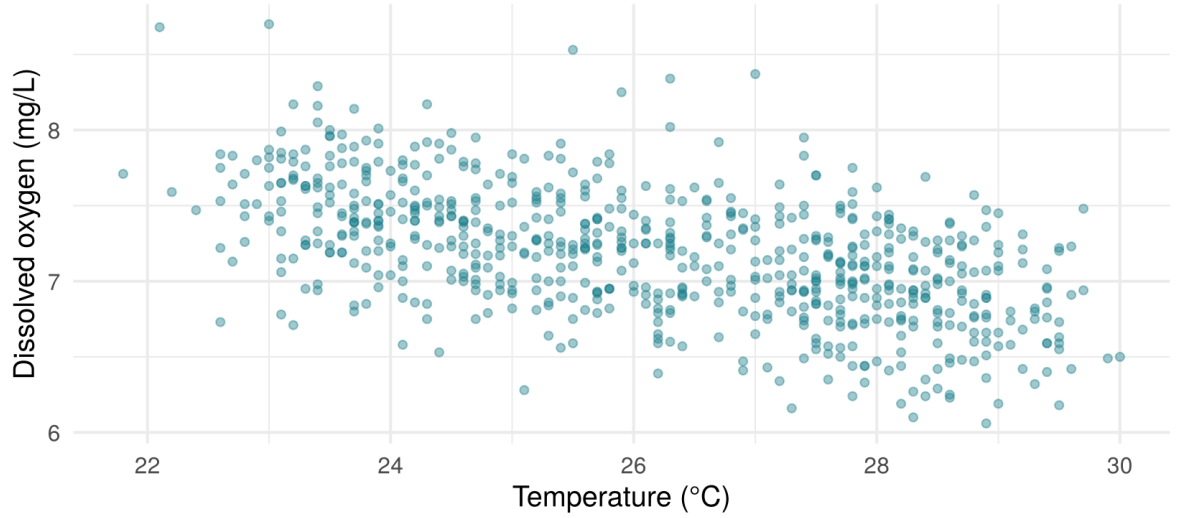
> › **À vous.** Dans l'enquête, les ménages dirigés par des femmes cultivent-ils les algues (`does_seaweed`) aussi souvent que ceux dirigés par des hommes ? Construisez le tableau, les pourcentages par ligne, vérifiez les effectifs attendus et faites le test.

Corrélation : Pearson ou Spearman

Un **coefficient de corrélation** (entre −1 et +1) mesure comment deux variables numériques varient ensemble : 0 = pas d'association, ±1 = association parfaite. Le **r de Pearson** mesure une association **linéaire** (en ligne droite) et utilise les valeurs ; le **ρ (rho) de Spearman** utilise les **rangs** et mesure une association **monotone** (toujours croissante ou toujours décroissante, pas forcément droite). Spearman est le choix non paramétrique : robuste aux valeurs extrêmes et aux variables asymétriques.

Température et oxygène dissous

```
ggplot(wq, aes(temp_C, DO_mgL)) + geom_point(alpha = 0.4, colour = "#1b7f8c", na.rm = TRUE) +
  labs(x = "Temperature (°C)", y = "Dissolved oxygen (mg/L)") + theme_c()
```




```
cor.test(wq$temp_C, wq$DO_mgL)          # Pearson by default; NA pairs are dropped
```

```
#>
#>  Pearson's product-moment correlation
#>
#> data:  wq$temp_C and wq$DO_mgL
#> t = -17.472, df = 698, p-value < 2.2e-16
#> alternative hypothesis: true correlation is not equal to 0
#> 95 percent confidence interval:
#>  -0.6011396 -0.4978562
#> sample estimates:
#>       cor
#> -0.5516088
```

Le nuage est à peu près une bande droite sans points extrêmes → Pearson est adapté : r = −0,55 (IC 95 % −0,60 à −0,50), p < 0,001. Une eau plus chaude contient moins d'oxygène : une relation physique bien connue. `r^2` ≈ 0,30 : la température « explique » environ 30 % de la variation de l'O_2 dissous.

Croissance des algues et température : quand un coefficient trompe

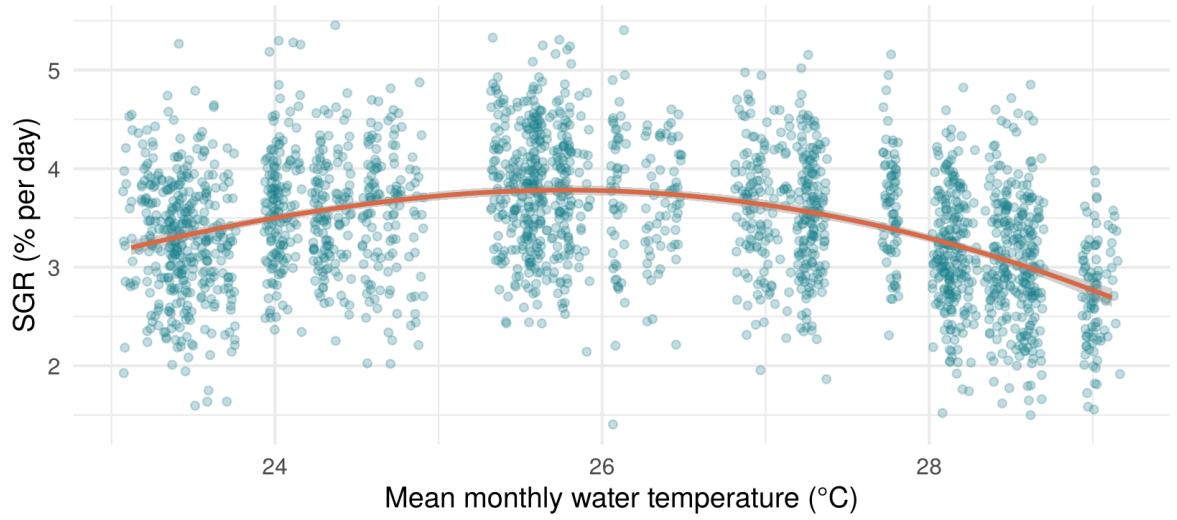
```
cor(seaweed$temp_mean, seaweed$sgr, use = "complete.obs")                    # Pe
arson
```

```
#> [1] -0.1865449
```

```
cor(seaweed$temp_mean, seaweed$sgr, use = "complete.obs", method = "spearman") # S
pearman
```

```
#> [1] -0.1875033
```

```
ggplot(seaweed, aes(temp_mean, sgr)) +
  geom_jitter(width = 0.05, alpha = 0.25, colour = "#1b7f8c", na.rm = TRUE) +
  geom_smooth(method = "loess", formula = y ~ x, colour = "#d9694a", na.rm = TRUE)
+  # flexible trend line
  labs(x = "Mean monthly water temperature (°C)", y = "SGR (% per day)") + theme_c
()
```



Les deux coefficients sont faibles (environ −0,19), ce qui suggère « la température compte peu ». Le graphique dit le contraire : la croissance **augmente** jusqu'à environ 25–26 °C puis **diminue**. La relation est forte mais **non monotone** : ni Pearson ni Spearman ne peuvent la décrire, leur valeur mélange la partie croissante et la partie décroissante. **Tracez toujours avant de calculer une corrélation** ; pour une telle courbe, décrivez-la avec le graphique (et, au niveau avancé, avec un modèle).

Deux autres rappels : **corrélation n'est pas causalité** (les deux variables peuvent dépendre d'une troisième, par exemple la saison), et avec des milliers de points même une corrélation minuscule est « significative » — regardez le coefficient, pas seulement p.

> ! **Une question, un test.** Chaque test a 5 % de risque de faux positif quand H0 est vraie. Si vous faites 20 tests « pour voir », environ un sera significatif par hasard. Décidez d'abord vos questions, testez-les, et rapportez-les toutes — y compris les non significatives.

Travail d'application et quiz

Travail d'application I10

Script `scripts/i10_tests.R` . Pour chaque question, **écrivez d'abord quel test vous choisissez et pourquoi** (une ligne de commentaire), puis tracez, puis testez.

by Aroo Falinirina

1. SGR des algues, saison sèche vs saison des pluies (test t de Welch). Différence des moyennes sèche − pluies (3 décimales) et borne inférieure de son IC à 95 % (3 décimales).
2. Revenu mensuel selon `head_sex`, avec le test de Wilcoxon : p-value (3 décimales) ?
3. Températures moyennes des stations, 2025 vs 2024 (test t apparié) : p-value (3 décimales) ?
4. Tableau `sex × technique` des cultivateurs : plus petit effectif **attendu** (2 décimales), et p-value de `chisq.test()` (3 décimales).
5. Corrélation de Pearson entre `temp_C` et `DO_mgL` (3 décimales).
6. Corrélation de Spearman entre `temp_mean` et `sgr` dans les données d'algues (3 décimales). Pourquoi est-elle trompeuse ?
7. Écrivez une phrase de résultat pour les questions 1 et 4.

Question 1 : `tt <- t.test(sgr ~ season, data = seaweed)` ; `tt$estimate` contient les deux moyennes (dry d'abord, ordre alphabétique) et `tt$conf.int` l'intervalle. Question 4 : `chisq.test(tab)$expected`, puis `min()`.

Quiz : répondez en ligne sur le site du cours (votre score y est enregistré).