I12 · Séance d’exercices

~3.5 h

À quoi sert cette séance

Pas de nouvelle notion : six exercices indépendants pour **pratiquer** les séances I0 à I11 sur les fichiers **bruts**, avant le projet final. Chaque exercice a son propre quiz (**deux tentatives**, la meilleure compte) et sa propre solution, ouverte quand vous avez utilisé vos tentatives ou obtenu tous les points. Ces quiz comptent pour les 80 % nécessaires au niveau avancé.

- Écrivez tout dans un seul script `scripts/i12_practice.R` , une section par exercice (**Ctrl + Maj + R**).
- Chaque exercice part d’un fichier du dossier `data/` : ne réutilisez pas les objets d’un autre exercice.
- Les indices sont gratuits : ils ne coûtent pas de points.

~ **Données (simulées).** Les fichiers que vous connaissez depuis les séances I2 à I4 : les mesures à la sonde des **10 stations de qualité de l’eau** (`water_quality_long.csv` , `water_quality_wide.csv` , `stations.csv`) et l’**enquête ménages** (`survey_households.csv` , `survey_members.csv` , `survey_assets.csv` ; 420 ménages interrogés en 2025 par quatre enquêteurs, avec quelques doublons et des réponses en texte libre). Voir les séances I2 et I4 pour leur mode de collecte.

⇩ all intermediate data (zip)

Exercice 1 — Import, codes manquants et dates

Séances I0–I1. Importez `water_quality_long.csv` **sans** le nettoyer.

1. Combien de températures sont codées `-999` ?
2. Combien de valeurs de pH valent `0` ?
3. Combien de valeurs d’oxygène dissous sont `NA` ?
4. Convertissez `date` en `Date` (format `jj/mm/aaaa`). Combien de mesures ont été faites en **juillet** (toutes années confondues) ?
5. Combien de jours séparent la première et la dernière date d’échantillonnage ?
6. Remplacez `-999` par `NA` : température moyenne (2 décimales) ?

by Aroo Falinirina

> `sum(x == -999, na.rm = TRUE)` compte un code ; `lubridate::month()` donne le numéro du mois ; soustraire deux dates donne un nombre de jours (`as.numeric()`).

Quiz : répondez en ligne sur le site du cours (votre score y est enregistré).

Exercice 2 — Restructurer et joindre

Séances I2–I3.

1. Importez `water_quality_wide.csv` (avec `check.names = FALSE` pour garder les noms des mois) et passez-le en format **long** : une ligne par station et par mois, colonnes `station` , `month` , `temp` . Nombre de lignes ?
2. Joignez la zone de chaque station (`stations.csv`). Température moyenne des stations du **Sud** en `2024-07` (2 décimales) ?
3. Quel mois (`aaaa-mm`) a la température moyenne la plus élevée sur l'ensemble des stations ?
4. Enquête : combien de lignes de `survey_members.csv` ont un `hh_id` qui n'existe **pas** dans `survey_households.csv` ?
5. `survey_assets.csv` : combien de ménages **différents** possèdent au moins une `pirogue` ?

> `pivot_longer(wide, -station, names_to = "month", values_to = "temp")` ; `anti_join()` garde les lignes **sans** correspondance ; `n_distinct()` compte les valeurs différentes.

Quiz : répondez en ligne sur le site du cours (votre score y est enregistré).

Exercice 3 — Données d'enquête et texte

Séance I4. Importez `survey_households.csv` avec `na.strings = ""` .

1. Combien y a-t-il de lignes **doublons exacts** ?
2. Après les avoir supprimées : combien de ménages citent `fishing` dans leurs `activities` ?
3. Nettoyez `mpa_benefits` (espaces et majuscules). Parmi les ménages qui ont répondu, quel pourcentage est « Agree » ou « Strongly agree » (1 décimale) ?
4. `main_income` le plus fréquent ?
5. Nombre moyen d'activités par ménage (2 décimales) ?

by Aroo Falinirina

> `sum(duplicated(h))` ; `str_detect()` ; `str_to_sentence(str_squish(x))` ; les activités sont séparées par `;` , donc le nombre d'activités est le nombre de `;` + 1 (`str_count()`).

Quiz : répondez en ligne sur le site du cours (votre score y est enregistré).

Exercice 4 — Boucles, conditions et fonctions

Séances I5–I6. Utilisez le checkpoint nettoyé `I2_water_quality_clean.csv` .

1. Écrivez une fonction `cv(x)` qui renvoie le **coefficient de variation** en % (100 × ET / moyenne, en ignorant les NA). Appliquez-la à `salinity_psu` pour chaque station (avec une boucle, `sapply()` ou `group_by()`). Quelle station a le CV le plus élevé, et combien vaut-il (2 décimales) ?
2. Combien de mesures ont une température ≥ 28 °C ?
3. Classez la turbidité : `clear` (< 3 NTU), `moderate` (3 à < 6), `turbid` (≥ 6). Combien de mesures `turbid` ?

> `sapply(split(w$salinity_psu, w$station), cv)` applique `cv()` à chaque station. Pour 3 classes, imbriquez deux `ifelse()` ou utilisez `case_when()` .

Quiz : répondez en ligne sur le site du cours (votre score y est enregistré).

Exercice 5 — Graphiques

Séances I7–I8. Même fichier de qualité d'eau nettoyé.

1. Tracez l'**oxygène dissous moyen par mois calendaire** (1–12, toutes années et stations confondues) en points reliés par une ligne, avec un IC à 95 %. Quel mois a l'O_2 moyen le plus faible, et combien vaut-il (2 décimales) ?
2. Faites des boxplots de la turbidité par station, colorés par zone (joignez `stations.csv`), ordonnés par médiane, avec un titre et des axes clairs. Enregistrez en PNG 16 × 10 cm.
3. Répondez aux questions sur le code ggplot ci-dessous.

Quiz : répondez en ligne sur le site du cours (votre score y est enregistré).

Exercice 6 — Choisir et faire un test

Séances I9–I10. Pour chaque question, **tracez d'abord**, puis choisissez et justifiez le test en commentaire.

1. Turbidité aux stations du **Nord** vs du **Sud** (fichier de qualité d'eau nettoyé + `stations.csv`). La turbidité est asymétrique à droite. Turbidité médiane au Sud (NTU) ?
2. Quel test choisissez-vous pour la question 1 (voir le quiz) ?
3. Corrélation de Spearman entre salinité et turbidité (toutes les mesures, 3 décimales).
4. Enquête (`I4_households_clean.csv` + zone depuis `villages.csv`) : la proportion de ménages cultivant les algues (`does_seaweed`) diffère-t-elle entre les trois zones ? Plus petit effectif attendu (1 décimale) et p-value du khi-deux (3 décimales).

> Question 4 : `table(hh$zone, hh$does_seaweed)` est un tableau 3 × 2 ; `chisq.test()` fonctionne comme pour un 2 × 2 (pas de correction de Yates au-delà de 2 × 2).

Quiz : répondez en ligne sur le site du cours (votre score y est enregistré).

by Aroo Falinirina